Technische Universität Berlin

Fakultät VII - Wirtschaft und Management
Institut für Betriebswirtschaftslehre
Fachgebiet Marketing

Bericht im Modul

Marktforschung und Datenanalyse

Menschliche vs. synthetische Personas in der visuellen Marketingforschung

Eine empirische Untersuchung zur Replikation von Konsumentenbewertungen auf symbolisch konnotierte Kleidungsstile

Vorgelegt von

Jiayu Zhao, Matr.-Nr.: 0530369
Xiaolan Xu, Matr.-Nr.: 0530368
Franz Wendel, Matr.-Nr.: 0507346

Betreuerin

Anna-Maria Hempel

Berlin, 21. August 2026

Selbstständigkeitserklärung

Hiermit erklären wir, dass wir die vorliegende Arbeit selbstständig und eigenhändig sowie ohne unerlaubte fremde Hilfe und ausschließlich unter Verwendung der aufgeführten Quellen und Hilfsmittel angefertigt haben.

Sofern KI-Tools verwendet wurden, haben wir Produktnamen, Hersteller, die jeweils verwendete Softwareversion und die Art der Nutzung (z.B. sprachliche Überprüfung und Verbesserung der Texte, systematische Recherche) benannt. Wir verantworten die Auswahl, die Übernahme und sämtliche Ergebnisse des von uns verwendeten KI-generierten Outputs vollumfänglich selbst.

Produktname: ChatGPT EDU

Hersteller: OpenAI

Verwendete Softwareversion: GPT-4o (Stand: August 2026)

Art der Nutzung: Unterstützung bei der sprachlichen Überprüfung, Verbesserung der Texte sowie bei der systematischen Recherche und Quellenangaben.

Berlin, den 21. August 2026

Jiayu Zhao		
Jiayu Zhao	Xiaolan Xu	Franz Wendel

Inhaltsverzeichnis

1 Einleitung **1**
- 1.1 Problemstellung und Relevanz [Franz Wendel] . . . 1
- 1.2 Zielsetzung und Forschungsfrage [Franz Wendel] . . . 1
- 1.3 Aufbau der Arbeit [Franz Wendel] . . . 1

2 Theoretischer Hintergrund **2**
- 2.1 Visuelle Stimuli und symbolische Konsumbedeutung [Franz Wendel] . . . 2
- 2.2 Synthetische Personas in der Marktforschung [Franz Wendel] . . . 2
- 2.3 Replikationsvalidität synthetischer Stichproben [Franz Wendel] . . . 2
- 2.4 Forschungsmodell und Hypothesen [Franz Wendel, Xiaolan Xu] . . . 3

3 Methodik **4**
- 3.1 Untersuchungsdesign [Franz Wendel] . . . 4
- 3.2 Stimulusmaterial und Pretest [Franz Wendel] . . . 4
- 3.3 Stichprobe und Datenerhebung . . . 4
  - 3.3.1 Datenerhebung der menschlichen Befragten [Franz Wendel] . . . 4
  - 3.3.2 Generierung und Befragung der synthetischen Personas [Franz Wendel] . . . 4
- 3.4 Operationalisierung und Erhebungsinstrument [Franz Wendel] . . . 5
- 3.5 Datenaufbereitung und statistische Analyse [Franz Wendel] . . . 5

4 Ergebnisse **7**
- 4.1 Deskriptive Ergebnisse und Stimulusvalidierung [Franz Wendel] . . . 7
- 4.2 Überprüfung der Hypothesen . . . 8
  - 4.2.1 Replikation der Mittelwerte (H1) [Jiayu Zhao] . . . 8
  - 4.2.2 Replikation der Varianz (H2) [Jiayu Zhao] . . . 11
  - 4.2.3 Agreement-Replikation als ergänzende Analyse [Jiayu Zhao] . . . 12
  - 4.2.4 Zusammenfassende Bewertung von H1 und H2 [Jiayu Zhao] . . . 13
  - 4.2.5 Replikation von Subgruppenmustern (H3) [Xiaolan Xu, Franz Wendel] . . . 13
- 4.3 Vergleich der eigenständigen Datenanalyse mit dem ChatGPT Data Analyst [Xiaolan Xu] . . . 18
  - 4.3.1 Replikation der Mittelwerte . . . 18
  - 4.3.2 Replikation der Varianz . . . 19
  - 4.3.3 Replikation der Subgruppenmuster . . . 20
- 4.4 Zusammenfassung der zentralen Ergebnisse [Franz Wendel] . . . 20

5 Diskussion **22**
- 5.1 Interpretation der Ergebnisse [Xiaolan Xu] . . . 22
- 5.2 Implikationen für den Einsatz synthetischer Personas in der Marktforschung [Xiaolan Xu] . . . 22
- 5.3 Limitationen und zukünftiger Forschungsbedarf [Franz Wendel] . . . 23
- 5.4 Fazit [Xiaolan Xu] . . . 23

Literaturverzeichnis **24**

A Aktueller Empirischer Forschungsstand **26**

B Stimulusübersicht **27**

C Prompts und Code **28**
- C.1 Prompts . . . 28
  - C.1.1 Chinesisch . . . 28
  - C.1.2 Deutsch . . . 29
- C.2 Code . . . 32

Abbildungsverzeichnis

1 Stilerkennungsquote je K1-Stimulus und Datenquelle 7
2 Mittelwerte der Stilwahrnehmungsdimensionen nach Datenquelle und Komplexitätsstufe 8
3 Mittelwertreplikation von liking_mean nach Komplexitätsstufe 9
4 Mittelwertreplikation von wertigkeit_mean nach Komplexitätsstufe 10
5 Mittelwertreplikation von cons_mean nach Komplexitätsstufe 10
6 Within-Stimulus-ICC(A,1) der conn_*-Profile nach Komplexitätsstufe 13
7 ICC(A,1) von liking_mean nach Komplexitätsstufe 13
8 ICC(A,1) von wertigkeit_mean nach Komplexitätsstufe 14
9 ICC(A,1) von cons_mean nach Komplexitätsstufe 14
10 ICC(A,1) von price_expectation_eur nach Komplexitätsstufe 14
11 Replikationsgüte der Subgruppenmuster in Abhängigkeit von der Stimuluskomplexität 16
12 Beobachtete Matching Accuracy und erwartete Zufallstrefferquote nach Stimuluskomplexität . . . 17
13 Bootstrap-Konfidenzintervalle der Replikationskennwerte nach Stimuluskomplexität 18
14 Replikation der Mittelwerte (RStudio vs. ChatGPT Data Analyst) 19
15 Replikation der Varianz (RStudio vs. ChatGPT Data Analyst) 20
16 Replikationskennwerte nach Stimuluskomplexität (ChatGPT-Analyse) 21
17 Bootstrap-Konfidenzintervalle der Replikationskennwerte (ChatGPT-Analyse) 21

Code- und Promptverzeichnis

C.1 Systemprompt (chinesisch) 28
C.2 Persona Prompt (chinesisch) 28
C.3 Prompt Einzelprodukt (chinesisch) 28
C.4 Prompt Produktkombinationen (chinesisch) 29
C.5 Systemprompt (deutsch) 29
C.6 Persona Prompt (deutsch) 30
C.7 Prompt Einzelprodukt (deutsch) 30
C.8 Prompt Produktkombinationen (deutsch) 31
C.9 R-Code zur Verarbeitung von Mittelwerten und Varianzen (conn_*) 32
C.10 R-Code zur Analyse der Subgruppenmuster (H3) 33

Tabellenverzeichnis

1 Deskriptive Statistik der primären abhängigen Variablen nach Komplexität und Datenquelle 7
2 Mittelwertreplikation der Stilwahrnehmungsdimensionen (conn_*) 8
3 Mittelwertreplikation der zusammengefassten Bewertungsmaße 9
4 Mittelwertreplikation der Preiserwartung 10
5 Genauigkeit der kategorialen Stilerkennung in K1 11
6 Varianzreplikation der Stilwahrnehmungsdimensionen (conn_*) 11
7 Varianzreplikation der zusammengefassten Bewertungsmaße und der Preiserwartung 12
8 Absolute Übereinstimmung auf Individualebene (ICC(A,1)) nach Konstrukt und Komplexitätsstufe 12
9 Zusammenfassende Bewertung der Hypothesen H1 und H2 15
10 Replikation des CVPA-Subgruppenmusters im personengemittelten Liking-Index (H3) 15
11 Kennwerte der Subgruppenreplikation mit 95-%-Bootstrap-Konfidenzintervallen nach Stimuluskomplexität 17
A.1 Aktuelle empirische Untersuchungen 26
B.1 Eingesetzte Stimuli der Hauptstudie 27

1 Einleitung

1.1 Problemstellung und Relevanz [Franz Wendel]

Große Sprachmodelle (Large Language Models (LLM)) bieten der Marktforschung die Möglichkeit, Befragungsdaten nicht mehr ausschließlich bei Menschen, sondern synthetisch zu erheben, sogennante *Silicon Samples* (Argyle et al., 2023; Sarstedt et al., 2024). Synthetische Daten bieten gegenüber menschlichen Daten enorme ökonomische Vorteile, da sie kostengünstig, skalierbar und schnell verfügbar sind (Brand et al., 2023; Yoo et al., 2025). Inwieweit diese Daten verwendet werden können, ist Gegenstand aktueller Forschung. In Bezug auf die Aussagefähigkeit zeigt sich schnell, dass Mittelwerte oder grobe Rangfolgen gut repliziert werden können. Im Gegensatz dazu versagen synthetische Stichproben in Bezug auf die Replikation von Varianz und der Subgruppenmuster: die Varianz wird komprimiert und Informationen von Subgruppen werden abgeschwächt (Bisbee et al., 2024; Shrestha et al., 2024).

Ein Großteil aktueller empirischer Untersuchungen konzentriert sich auf textbasierte Einstellungs- und Politikbefragungen, Conjoint-Aufgaben sowie einfache visuelle Stimuli (Argyle et al., 2023; Brand et al., 2023; Rahimipouri & Ghaitaranpour, 2026). Hieraus ergibt sich die Forschungslücke der vorliegenden Arbeit. Die Literatur in Bezug auf die Generierung synthetischer Daten, hat visuelle Stimuli mit symbolischer Wirkung bislang kaum adressiert. Diese Art von Stimuli ist jedoch wichtg, da Konsumgüter nicht allein über funktionale Eigenschaften, sondern auch über ihre Bedeutung bewertet werden (Levy, 1959; McCracken, 1986). Aus diesem Grund untersucht die vorliegende Arbeit die Replikationsgüte synthetischer Personas systematisch unter Berücksichtigung symbolisch konnotierter Stimuli.

1.2 Zielsetzung und Forschungsfrage [Franz Wendel]

Vor diesem Hintergrund soll untersucht werden, wie LLM-basierte Personas, die aus realen Personen-Profilen gespiegelt werden, die Antworten der Menschen reproduzieren. Die Untersuchung wird von folgender Forschungsfrage geleitet:

> *In welchem Ausmaß replizieren synthetische Personas Mittelwerte, Varianz und Subgruppenmuster in visuellen Marketingbefragungen mit symbolisch konnotierten Stimuli?*

Die Forschungsfrage adressiert drei statistische Ebenen. Zunächst wird die Mittelwertreplikation getestet. Weiterhin wird untersucht, ob Varianz- und Subgruppeneigenschaften reproduzierbar sind. Letztere sind als Gegenstand aktueller Untersuchungen nicht hinreichend belegt (Bisbee et al., 2024; Shrestha et al., 2024). Ziel ist eine differenzierte Aussage darüber zu treffen, ob Silicon Samples im Bezug auf visuelle Stimuli mit symbolischer Bedeutung passende Informationen liefern können und wo Grenzen liegen.

1.3 Aufbau der Arbeit [Franz Wendel]

Aufbau und Vorgehen folgen den Phasen des Marktforschungsprozesses. Zu Beginn wird das Problem beschrieben und die Forschungsfrage hergeleitet (Kapitel 1). Darauf folgt der theoretische Rahmen, dieser bildet zusammen mit der Forschungsfrage die Grundlage für die Herleitung der Hypothesen Kapitel 2. Kapitel 3 umfasst das Untersuchungsdesign, die Operationalisierung der Konstrukte, die Datenerhebung sowie die Datenaufbereitung und Auswertungsplanung. Die Auswertung und Ergebnisdarstellung erfolgt in Kapitel 4; abschließend werden die Ergebnisse interpretiert und im Hinblick auf Implikationen und Limitationen diskutiert (Kapitel 5).

2 Theoretischer Hintergrund

2.1 Visuelle Stimuli und symbolische Konsumbedeutung [Franz Wendel]

Konsumgüter sind mit Bedeutung verbunden. Bereits Levy (1959) beschreibt, dass Produkte nicht nur wegen ihrer Funktion, sondern wegen ihrer symbolischen Bedeutung gekauft werden. McCracken (1986) beschreibt die Wirkung kultureller Bedeutung von der Kultur über das Gut zum Konsumierenden. Belk (1988) und Solomon (1983) zeigen, dass Produkte als Erweiterung des Selbst wirken. Mode ist für diese Mechanismen ein Anwendungsfeld. Stilrichtungen wie Minimalismus, Boho oder HipHop/Streetwear sind Stilrichtungen, welchen eine Bedeutung zugeordnet werden kann. Sie aktivieren über Form, Farbe und Material spezifische symbolische Konnotationen. Individuelle Unterschiede in der Bedeutung visueller Produktästhetik für Menschen erfasst das Konstrukt Centrality of Visual Product Aesthetics (CVPA) (Bloch et al., 2003). Für Produktkombinationen kann stilistischer Konsistenz ebenfalls eine Bedeutung zugeordnet werden. Einheitlichkeit und Konsistenz kann eine individuelle ästhetische Bewertung erhöhen (Reber et al., 2004; Veryzer & Hutchinson, 1998).

2.2 Synthetische Personas in der Marktforschung [Franz Wendel]

Als synthetische Personas werden LLM-Instanzen bezeichnet, die per Prompt mit dem Profil einer realen oder konstruierten Person konditioniert werden. Nach einer initialen Konditionierung können sie Befragungsitems aus deren Perspektive beantworten. Argyle et al. (2023) zeigen unter dem Begriff der „algorithmic fidelity“, dass derartige Simulationen menschliche Antwortverteilungen approximieren können. Brand et al. (2023) berichten plausible Zahlungsbereitschaften und Preis-Absatz-Zusammenhänge in Conjoint-ähnlichen Aufgaben. Leitlinien für den Einsatz in der Konsumentenforschung formulieren Sarstedt et al. (2024). Sie identifizieren vorgelagerte Aufgaben (Pilot-Screening, Stimulusvorauswahl, Hypothesengenerierung) als stärkste Anwendungsfälle, nicht den Ersatz validierter menschlicher Daten. Die neuere Forschung weist die Tiefe der Personakonditionierung als zentralen Designparameter aus: Rein demografisch konditionierte Personas erreichen 74 % der Test-Retest-Konsistenz realer Befragter. Bei interviewbasierten generativen Agents steigt die Replikationsgüte auf 85 % (Park et al., 2024). Fine-Tuning auf individuellen Konsumhistorien kann die Vorhersagesicherheit von Kaufentscheidungen von 0,54 auf 0,86 weiter erhöhen (Li et al., 2025).

2.3 Replikationsvalidität synthetischer Stichproben [Franz Wendel]

Die Replikation lässt sich in drei Dimensionen bewerten. Während sich Mittelwerte gut replizieren lassen (Argyle et al., 2023; Brand et al., 2023), verhält es sich bezüglich Varianz anders. Bisbee et al. (2024) beschreiben, dass LLM-Antworten stark auf wenige Standardantworten reduzieren und dadurch zu wenig streuen. Die zu geringe Streuung verzerrt Konfidenzintervalle und Effektschätzungen und macht die statistische Inferenz instabil. In Bezug auf die Replikation von Subgruppenunterschieden zeigen Shrestha et al. (2024) für nicht-westliche Populationen, dass demografisch erstellte Personas vor allem Sichtweisen wiedergeben, die in den Trainingsdaten am häufigsten vorhanden sind. Menschliche Vielfalt innerhalb einer Subgruppe bilden sie dagegen kaum ab. Für den deutschen Kontext beschreiben von der Heyde et al. (2025), dass LLM-basierte Personas nur bei stereotypischen Wählersubgruppen eine Wahlentscheidung vorhersagen können, gleichzeitig aber eine systematisch politisch Verzerrung vorliegt. Ein systematisches Review über 182 Veröffentlichungen kommt zu einem vergleichbarem Ergebnis: Prompting- und Modellierungstechniken verbessern die Abbildungstreue moderat. Daher sind synthetische Datenpunkte als heuristische und nicht als repräsentative Datenquelle zu verstehen (Kuric et al., 2026). Weiterhin bewerten aktuelle Untersuchungen die Abbildungstreue synthetischer Stichproben auf drei Ebenen: marginal (Verteilungen), strukturell (Zusammenhänge zwischen Variablen) und individuell. Jede dieser Ebenen kann unabhängig von den beiden anderen bewertet werden (Choi et al., 2026; Wang et al., 2026).

Visuelle Stimuli sind in der Literatur noch nicht vollumfänglich untersucht. Kumar und Garg (2010) vergleichen menschliche und KI-basierte Bewertungen zu sensorischen Lebensmittelpräferenzen über Geschlechts- und Altersgruppen hinweg. Bei Kurzvideo-Stimuli finden Shrestha et al. (2026) nur begrenzte Übereinstimmung zwischen multimodalen LLM-Personas und realen Befragten: Die Antwortverteilungen tendieren zur Mitte und Subgruppenunterschiede werden teils nicht repliziert, teils erst vom Modell eingeführt. Die Replikation bei Design-Screenshots fällt besser aus: Rieder et al. (2026) berichten, dass persona-konditionierte Agents 67 % der realen A/B-Test-Ausgänge treffen. Direkt anschlussfähig an modebezogene Stimuli ist der Befund von Hirakawa et al. (2024): GPT-4V repliziert ästhetische Konsensurteile über Mode-Outfits nur schwach bis moderat. Die Rangkorrelationen liegen zwischen $\rho = 0{,}12$ und 0,52, während menschliche Beurteilende untereinander Werte von 0,72 bis 0,82 erreichen. Anhang A ordnet den empirischen Forschungsstand der Jahre 2024–2026 (13 Veröffentlichungen) den drei Ebenen der Forschungsfrage zu. Offen bleibt damit, ob und wie synthetische Befragte symbolisch konnotierte visuelle Stimuli

verarbeiten. Keine der vorliegenden Veröffentlichungen simuliert Befragte gegenüber solchen Konsum-Stimuli mit 1:1 Spiegelung. Symbolische Bedeutung ist kulturell kodiert und daher potenziell gut im Trainingsmaterial eines LLM repräsentiert. Denkbar ist deshalb beides: eine besonders gute Replikation der Bedeutungsrichtung ebenso wie eine Überbewertung stereotyper Bedeutungsstärken.

2.4 Forschungsmodell und Hypothesen [Franz Wendel, Xiaolan Xu]

Das Forschungsmodell variiert auf Stimulusseite die Stilrichtung (Minimalismus, Boho, HipHop/Streetwear), die visuelle Komplexität (Einzelprodukt K1, Zwei-Produkt-Kombination K2, mehrteiliges Outfit-Ensemble K3) sowie innerhalb von K2 und K3 die Stilkonsistenz (konsistent vs. inkonsistent). Auf Stichprobenseite wird die Datenquelle (Mensch vs. synthetische Persona) verglichen. Die visuelle Komplexität wird als ordinalskalierte unabhängige Variable behandelt. Die drei Stufen bilden über die Anzahl der gebündelten Produkte ($1 < 2 < \sim 8$) eine geordnete Rangfolge. Die Abstände der Stufen können nicht als äquidistant interpretiert werden (Greving, 2007). Die Komplexität wird über ordinale Verfahren untersucht (s. Abschnitt 3.5). Primäre abhängige Variable ist die Produktpräferenz (Liking-Index). Ergänzend werden Preiserwartung, wahrgenommene Konnotationen und Stimmigkeit erfasst (s. Abschnitt 3.4). Aus dem Forschungsstand werden drei geschlossen formulierte (konfirmatorische) Hypothesen abgeleitet, die den drei Ebenen der Forschungsfrage entsprechen:

- **H1 (Mittelwerte):** Synthetische Personas replizieren die Mittelwerte der Präferenzurteile der menschlichen Stichprobe. Human- und synthetische Bewertungen gelten als praktisch äquivalent, wenn die Mittelwertdifferenz innerhalb eines vorab definierten Äquivalenzbereichs von ±0,5 Skalenpunkten liegt und die Äquivalenz durch einen Two One-Sided Tests (TOST) bestätigt wird.(**<empty citation>**)
- **H2 (Varianz):** Synthetische Personas weisen eine geringere Antwortvarianz auf als die menschliche Stichprobe (Bisbee et al., 2024).
- **H3 (Subgruppenmuster):** Es wird erwartet, dass die in der menschlichen Stichprobe identifizierten Subgruppenmuster in der synthetischen Stichprobe nur teilweise repliziert werden. Sprachmodelle können gruppenspezifische Antwortmuster grundsätzlich abbilden, weisen jedoch häufig geringere Streuungen, systematische Verzerrungen und kontextabhängige Übereinstimmungen auf (Argyle et al., 2023; Bisbee et al., 2024; Shrestha et al., 2024). Als zentrale theoriegeleitete Subgruppenvariable dient die Centrality of Visual Product Aesthetics (CVPA), da sie individuelle Unterschiede in der Bedeutung visueller Produktästhetik und damit verbundene Präferenzunterschiede bei visuellen Stimuli erfasst (Bloch et al., 2003). Die Replikationsgüte wird anhand von Matching Accuracy, Cohens κ, ARI, TVD und sCMAE beurteilt.

Ihrer Form nach sind H1 bis H3 geschlossene Unterschiedshypothesen (H1 mit Effektgröße, H2 und H3 mit Effektrichtung). Die in H3 erwartete Abschwächung entspricht einer Moderation des CVPA-Effekts durch die Datenquelle. Für den Verlauf der Replikationsgüte über die ordinale Komplexitätsachse wird keine konfirmatorische Hypothese formuliert, da der Forschungsstand zwei gegenläufige Richtungsvermutungen aufzeigt. Mit steigender Anzahl an Produkten je Stimuli muss eine Bewertung mehrere verschiedene Produkte integrieren. LLM-Bewertungen zeigen jedoch bei komplexen visuellen Stimuli begrenzte Übereinstimmung mit menschlichen Bewertungen (Hirakawa et al., 2024; Shrestha et al., 2026). Daraus folgt eine schlechtere Replikation. Zugleich könnten mehrfach symbolisch konnotierte Stilensembles die Replikation verbessern, da ein mehrteiliges Ensemble nicht als Summe unabhängiger Einzelteile, sondern als Ganzes mit eigener kultureller Bedeutung aufzufassen ist (Koffka, 1935). Der Komplexitätszusammenhang wird daher nicht konfirmatorisch untersucht, sondern geht als Sensitivitätsachse in die anderen Analysen ein.

3 Methodik

3.1 Untersuchungsdesign [Franz Wendel]

Die Untersuchung wird als quantitative Studie durchgeführt, als Primärforschung angelegt und verfolgt einen konfirmativen Untersuchungsanspruch. Die Datenerhebung kombiniert eine standardisierte schriftliche Online-Befragung mit einer experimentellen Variation der Stimulusfaktoren in einem faktoriellen Within-Subject-Quasi-Experiment (Eifler & Leitgöb, 2022). Stilrichtung, Komplexität und Stilkonsistenz werden über die Stimuluskonstruktion manipuliert und allen Befragten vollständig vorgelegt. Das Within-Subject Design erhöht die statistische Power, da die konstanten Eigenschaften jeder Person als eigene Kontrollvariable fungiert (Charness et al., 2012). Die Zuweisung zur Datenquelle (Mensch vs. KI-Persona) erfolgt nicht zufällig, sondern direkt 1:1 gespiegelt. Damit liegt ein Quasi-Experiment vor (Eifler & Leitgöb, 2022). Um die Vergleichbarkeit der beiden Datenquellen zu gewährleisten, wird jede synthetische Persona aus genau einem realen Befragtenprofil erstellt. Auf Stimulusebene werden Hintergrund, Beleuchtung, Markenfreiheit und der Produktmaßstab konstant gehalten.

3.2 Stimulusmaterial und Pretest [Franz Wendel]

Das Stimulusset der Hauptstudie umfasst elf Bildstimuli: sechs Einzelprodukte (K1; je Stil ein Oberteil und ein Unterteil), drei Zwei-Produkt-Kombinationen (K2; stilkonsistent Minimalismus und Boho, stilinkonsistent Hip-Hop × Boho) sowie zwei mehrteilige Outfit-Ensembles (K3; konsistent vs. inkonsistent). Die drei Komplexitätsstufen bilden eine ordinale Abstufung der Bündelgröße (1, 2, ~ 8 Produkte). Über die ungleiche Distanz zwischen den Stufen wird keine Annahme getroffen. Eine Übersicht enthält Anhang B. Alle Bilder folgen einheitlichen Spezifikationen (neutraler Hintergrund, gleichmäßige Ausleuchtung, entfernte Logos, konstanter Maßstab pro Produkt), um konkurrierende Bedeutungsquellen und Größenkonfundierungen auszuschließen.

Der Auswahl ging ein Pretest voraus ($n = 22$ menschliche/synthetische Befragte). Durch den Prestest konnten die Stimuli und Items des Fragebogens weitestgehend validiert (Ausnahme siehe unten) werden. Die Stilzuordnung ist hoch ausgefallen (73 bis 100 %). Das Kategorisierungskriterium von ≥ 70 % war damit überwiegend erfüllt. Die absolute Konnotationsstärke blieb für einige Adjektive unter der Einschlussschwelle. Für die Hauptstudie wurde deshalb eine Änderung der symbolisch konnotierten Adjektiven vorgenommen. Die für den Pretest verwendeten Konnotationsadjektive wurden durch getestete des Fachgebiets Marketing ersetzt.

3.3 Stichprobe und Datenerhebung

3.3.1 Datenerhebung der menschlichen Befragten [Franz Wendel]

Die menschliche Stichprobe umfasst $N = 61$ vollständige Befragungen aus einer standardisierten Online-Befragung. Grundgesamtheit sind junge, modeinteressierte Konsumenten. Die Auswahl erfolgte als nicht zufällige, willkürliche Auswahl im Umfeld der Studierendenschaft. Der Stichprobenumfang war durch die Feldzeit des studentischen Projekts (Erhebungszeitraum 21 Tage) begrenzt. Ein großer Teil der Befragten ist chinesischsprachig. Die Befragung wurde deshalb zweisprachig durchgeführt: $n = 47$ Personen mit chinesischem sprachlichem und kulturellem Hintergrund beantworteten die chinesischsprachige Fassung des Fragebogens. Die übrigen $n = 14$ Personen die deutschsprachige Fassung. Die chinesische Fassung wurde von muttersprachlichen Projektmitgliedern übersetzt. Skalenformate, Itemreihenfolge und Kontrollfragen waren in beiden Fassungen identisch. Jede Person bewertete alle elf Stimuli, innerhalb der jeweiligen Komplexitätsstufe in randomisierter Reihenfolge auf fünfstufigen Ratingskalen (Likert-Skalen und bipolare semantische Differenziale) (Greving, 2007). Die Stichprobe ist demografisch homogen (überwiegend Studierende) und nicht bevölkerungsrepräsentativ. Für den internen Replikationsvergleich ist dies tolerierbar, für die Generalisierung ist es eine Einschränkung. Wegen der nicht zufälligen Auswahl sichern die Signifikanztests den internen Paarvergleich ab und nicht die Inferenz auf eine Grundgesamtheit (s. Abschnitt 5.3; Henrich et al., 2010).

3.3.2 Generierung und Befragung der synthetischen Personas [Franz Wendel]

Für jede reale Person wurde eine synthetische Persona erzeugt, die exakt deren Profil erhält: Alter, Geschlecht, Tätigkeit, Kulturkreis, Haushaltseinkommen, Bekleidungsbudget, Lieblingsmarken, Modeinvolvement sowie die aggregierten Traitwerte (CVPA, Need for Uniqueness, Preference for Consistency, Stilaffinitäten; Bloch et al., 2003; Cialdini et al., 1995; Ruvio et al., 2008; Tian et al., 2001). Der Prompt besteht aus Teilen.: Zunächst einer konstanten Rollenanweisung (Beantwortung ausschließlich aus der Perspektive der Person, keine Zusatzinformationen), dem Personaprofil und dem jeweiligen Stimulus mit den Items im exakten Wortlaut und Antwortformat des gefeldeten Fragebogens. Jede Persona wurde in einem neuen Chat ohne Memory Funktion befragt, um das Übertragen von

Informationen zwischen Chats auszuschließen. Die Antworten wurden als strukturierte, maschinenlesbare Ausgabe erzwungen und in einem .csv Dokument gesammelt. Die Erhebungssprache wurde innerhalb jedes Human-Synthetic-Paares konstant gehalten. Personas chinesischsprachig Befragter erhielten Rollenanweisung, Profil und Items in chinesischer Fassung (s. Anhang C.1.1), die übrigen in der deutschen Fassung (s. Anhang C.1.2). Damit unterscheidet die Sprache nicht die Datenquellen. Sie variiert jedoch systematisch mit dem Kulturkreis der Teilstichproben (s. Abschnitte 4.2.5 und 5.3).

3.4 Operationalisierung und Erhebungsinstrument [Franz Wendel]

Alle elf Stimuli wurden mit einem einheitlichen Itemblock auf fünfstufigen Ratingskalen bewertet. Primäre abhängige Variable ist die Produktpräferenz als Mittelwertindex aus drei Likingitems („Das Produkt gefällt mir gut.“, „Ich mag das Produkt.“, „Ich finde das Produkt ansprechend.“; 1 bis 5). Je Stimulus wurden zudem sechs Konnotationsitems (athletisch, urban, naturverbunden, romantisch, reduziert, konservativ), drei bipolare Wertigkeitsdifferenziale (minderwertig/hochwertig, einfach/luxuriös, billig/teuer) und eine offene ganzzahlige Preisschätzung in Euro erhoben. Die Konnotationspaare athletisch/urban (HipHop), naturverbunden/romantisch (Boho) und reduziert/konservativ (Minimalismus) bilden die intendierten Stilprofile ab. Bei K1 kam eine Forced-Choice-Stilzuordnung hinzu (HipHop/Streetwear, Minimalismus, Hippie/Boho, keine der Genannten). Bei K2 und K3 traten an ihre Stelle drei Stilzuordnungsratings. Dort wurden zusätzlich drei Stimmigkeitsdifferenziale (uneinheitlich/einheitlich, unstimmig/stimmig, unharmonisch/harmonisch) und ein Manipulation-Check zur Produktanzahl in einem offenen Antwortfeld erhoben. Der Personenblock erfasst die Traitkonstrukte in verkürzter Form mit je drei Items: CVPA mit einem Item je Subdimension (Bloch et al., 2003), Consumer Need for Uniqueness mit einem Item je Dimension (Ruvio et al., 2008; Tian et al., 2001) und Preference for Consistency (Cialdini et al., 1995). Hinzu kommen vier Stilpräferenzitems, ein Item zum Modeinvolvement, Demografie- und Konsumangaben sowie eine offene Suspicion-Probe. Alle Traitwerte gingen über ihre Mittelwerte in die Personaprofile ein. CVPA und Need for Uniqueness dienten zusätzlich als personenbezogene Variablen der Subgruppenanalyse (s. Abschnitt 3.5). Die Objektivität von Durchführung und Auswertung sichert die vollstandardisierte Online-Befragung ohne Interviewereinfluss. Die Reliabilität der Mittelwertindizes ist als interne Konsistenz hoch (Cronbachs α Mensch/Persona: Liking 0,93/0,99, Wertigkeit 0,78/0,86, Stimmigkeit 0,96/0,99). Die Konstruktvalidität der Stimulussymbolik wird über die diskriminante Validität der Konnotationsprofile geprüft (s. Abschnitt 4.1).

3.5 Datenaufbereitung und statistische Analyse [Franz Wendel]

Die Vorbereitung der Daten folgt den vier Schritten Richtigkeit prüfen, fehlende Werte, Ausreißer und Annahmen. Richtigkeit: Die Rohdatenexporte beider Datenquellen wurden vereinheitlicht (Kodierungen, Missing-Codes, abweichende Spaltenlayouts) und in ein gemeinsames Long-Format überführt (1 342 Zeilen; 61 Human-Synthetic-Paare). Die personenbezogenen Traitwerte und Demografiewerte der Personaprofile wurden über die Befragten-ID mit beiden Datenquellen über einen JOIN auf ID verknüpft. Fehlende Werte: Die primären abhängigen Variablen sind vollständig. Fehlende Angaben (Code -99) treten nur beim Manipulationscheck auf und sind daher nicht als Fehler zu werten. Imputation ist nicht notwendig. Ausreißer (Datenbereinigung): Als Plausibilitätskriterium dient der Manipulation-Check der Produktanzahl. Die drei K2-Stimuli zeigen zwei Produkte, die beiden K3-Ensembles acht. Die Bereinigung erfolgt auf zwei Stufen. Streng: Ausgeschlossen wird, wer bei mindestens einem Bündelstimulus (K2 oder K3) eine abweichende Produktanzahl angibt. Das betrifft 16 Befragte (26 %), die zusammen mit ihren synthetischen Zwillingen entfallen. Diese Stufe definiert die primäre Analysestichprobe mit $n = 45$ Paaren (K1: $n = 270$, K2: $n = 135$, K3: $n = 90$ gepaarte Beobachtungen) und liegt den Auswertungen zu H1 und H2 zugrunde. Weniger streng: Für H3 wird allein der K2-Check angewendet (acht Ausschlüsse, 13 %), womit $n = 53$ Paare verbleiben. Der Subgruppenvergleich zu H3 findet auf Personenebene über einen Median-Split statt. Die Fallzahl teilt sich dort auf zwei Zellen auf und die Teststärke fällt entsprechend schneller ab als bei den stimulusweisen Vergleichen. Die weniger strenge Bereinigung hält die Anzahl an Datenpunkten bei $n = 22$ und $n = 31$. Der Zugewinn an Datenpunkten wird durchgeführt, um statistische Aussagekraft zu verbessern. Die abweichende Fallzahl wird bei den H3-Befunden ausgewiesen (s. Abschnitt 4.2.5).

Die Auswertung erfolgte in R (R Core Team, 2025) in sechs Schritten entlang der drei Hypothesen. Schritt 1 umfasst deskriptive Statistiken und die Stimulusvalidierung (Stilerkennungsquote, Konnotationsdiskriminanz mittels einseitiger gepaarter Wilcoxon-Tests und Manipulation-Checks zu Produktanzahl). Schritt 2 prüft H1 mit gepaarten Mittelwertvergleichen (Wilcoxon-Vorzeichen-Rang-Tests für ordinale Items, t-Tests für die metrischen Indizes) sowie Äquivalenztests nach dem TOST-Verfahren mit einem Smallest Effect Size of Interest (SESOI) von $|d_z| < 0{,}2$ (Lakens, 2017). Die statistischen Hypothesen sind dort vertauscht (Nichtäquivalenz $H_0 : |d_z| \geq 0{,}2$ gegen Äquivalenz $H_1 : |d_z| < 0{,}2$). Erst ein signifikantes Ergebnis belegt praktische Äquivalenz. Schritt 3 prüft H2 über Varianzratios $\sigma^2_{\text{syn}} / \sigma^2_{\text{real}}$ je Stimulus mit Brown-Forsythe-Tests (Brown & Forsythe, 1974). Schritt 4 prüft H3 über den Vergleich

der Subgruppenmuster auf Personenebene. Verwendet werden ein Median-Split der CVPA bei 4,0, jeweils mit Welch-Tests je Datenquelle und einer Interaktionsprüfung über die gepaarten Differenzen. Hinzu kommen Korrelationen der kontinuierlichen Persona-Traitwerte. Schritt 5 berechnet Zusammenhangsmaße und Übereinstimmungsmaße auf Paarebene: Spearman-Korrelationen und Pearson-Korrelationen sowie Intraklassenkorrelationen für absolute Übereinstimmung, ICC(A,1)(Koo & Li, 2016; Shrout & Fleiss, 1979).

4 Ergebnisse

Das folgende Kapitel stellt die Befunde der Untersuchung dar. Zu Beginn werden die deskriptiven Kennwerte der bereinigten Stichprobe sowie die Validierung der Stimuli berichtet (Abschnitt 4.1). Darauf folgt die Prüfung der Hypothesen H1 bis H3 (Abschnitt 4.2), ergänzt um eine Agreement-Analyse auf Individualebene. Abschnitt 4.3 stellt die eigenständige Auswertung in RStudio den Ergebnissen des *ChatGPT Data Analyst* gegenüber. Abschnitt 4.4 fasst die zentralen Ergebnisse hypothesenweise zusammen.

4.1 Deskriptive Ergebnisse und Stimulusvalidierung [Franz Wendel]

Tabelle 1 zeigt die deskriptiven Kennwerte der bereinigten Stichprobe. Die synthetischen Personas bewerten die Stimuli auf K2 und K3 im Mittel positiver als die menschlichen Befragten (K2: $M = 3{,}15$ vs. $M = 2{,}92$; K3: $M = 3{,}99$ vs. $M = 3{,}86$). Bei K1 liegen die Mittelwerte nah beieinander ($M = 3{,}08$ vs. $M = 2{,}97$). Die offenen Preisschätzungen streuen in der menschlichen Stichprobe deutlich stärker ($SD = 76{,}29$ vs. $SD = 20{,}24$ € bei K1). Hervorzuheben ist, dass die Preiserwartungen mit der Produktanzahl steigen und daher nur innerhalb einer Komplexitätsstufe vergleichbar sind.

Tabelle 1: Deskriptive Statistik der primären abhängigen Variablen nach Komplexität und Datenquelle

		Liking (1–5)		Preiserwartung (€)		
Komplexität	Quelle	*M*	*SD*	*M*	*SD*	*n*
K1 (Einzelprodukt)	Mensch	2,97	1,04	33,38	76,29	318
	Synthetisch	3,08	1,26	30,06	20,24	318
K2 (Kombination)	Mensch	2,92	1,15	60,97	90,02	159
	Synthetisch	3,15	1,39	53,19	25,61	159
K3 (Ensemble)	Mensch	3,86	0,98	348,64	405,83	106
	Synthetisch	3,99	1,01	247,67	167,21	106

Anmerkungen. $N = 53$ nach Datenbereinigung (s. Abschnitt 3.5); n = Beobachtungen (Person × Stimulus).

Die Stimulusvalidierung bestätigt die beabsichtigte Symbolik, zeigt zugleich jedoch einen ersten Unterschied zwischen den Datenquellen. In der menschlichen Stichprobe erreichen vier der sechs K1-Stimuli das Kategorisierungskriterium von ≥ 70 % (Spannweite 58 bis 92 %). Die synthetischen Personas ordnen dieselben Stimuli zu 96 bis 100 % korrekt zu (s. Abbildung 1).

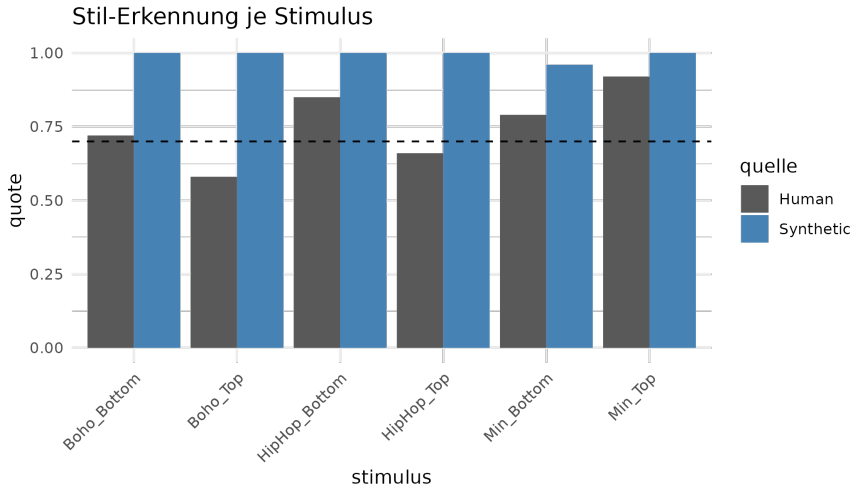


Abbildung 1: Stilerkennungsquote je K1-Stimulus und Datenquelle

Anmerkung. Eigene Darstellung.

4.2 Überprüfung der Hypothesen

4.2.1 Replikation der Mittelwerte (H1) [Jiayu Zhao]

Zur Prüfung von H1 werden die Mittelwerte der menschlichen und der synthetischen Stichprobe je Konstrukt und Komplexitätsstufe gegenübergestellt. Neben dem klassischen t-Test wird das TOST-Verfahren herangezogen, um praktische Äquivalenz innerhalb der in Abschnitt 3.5 definierten Äquivalenzgrenze prüfen zu können. Im Folgenden werden zunächst die Stilwahrnehmungsdimensionen, anschließend die zusammengefassten Bewertungsmaße, die Preiserwartung und die Stilerkennung dargestellt.

Stilwahrnehmung (conn_*). Die Mittelwertreplikation der sechs Stilwahrnehmungsdimensionen ist deutlich dimensionsabhängig (s. Tabelle 2 und Abbildung 2). In K1 erreichen conn_urban, conn_natur und conn_reduziert praktische Äquivalenz, während conn_athletisch, conn_roma und conn_konservativ das TOST-Kriterium nicht erfüllen. Besonders ausgeprägt sind die Abweichungen bei conn_roma und conn_konservativ, welche von den synthetischen Personas um 0,711 bzw. 0,707 Skalenpunkte unterschätzt werden. In K2 erreichen fünf der sechs Dimensionen praktische Äquivalenz; erneut bildet conn_roma die Ausnahme. Somit deutet sich für die romantische Stilkonnotation eine über beide Aufgabenbedingungen hinweg stabile richtungsbezogene Unterschätzung an.

Tabelle 2: Mittelwertreplikation der Stilwahrnehmungsdimensionen (conn_*)

		M					
Komplexität	Dimension	Mensch	Synth.	ΔM	p_t	p_{TOST}	Äquivalenz
K1	Athletisch	2,681	2,344	−0,337	0,004	0,075	nein
	Urban	2,919	3,119	+0,200	0,024	< 0,001	ja
	Natur	2,848	2,963	+0,115	0,162	< 0,001	ja
	Romantisch	2,496	1,785	−0,711	< 0,001	0,988	nein
	Reduziert	2,996	2,878	−0,119	0,137	< 0,001	ja
	Konservativ	3,007	2,300	−0,707	< 0,001	0,975	nein
K2[a]	Athletisch	2,449	2,311	−0,138	0,175	< 0,001	ja
	Urban	2,467	2,707	+0,240	0,066	0,024	ja
	Natur	2,889	2,982	+0,093	0,401	< 0,001	ja
	Romantisch	2,991	2,418	−0,573	< 0,001	0,739	nein
	Reduziert	3,258	3,404	+0,147	0,109	< 0,001	ja
	Konservativ	3,022	2,920	−0,102	0,365	< 0,001	ja

Anmerkungen. ΔM = synthetisch minus Mensch. Äquivalenz nach TOST bezogen auf die in Abschnitt 3.5 definierte Grenze.
[a] zu prüfen: umfasst K2 hier ausschließlich die Kombinationsstimuli oder K2 und K3 gepoolt? Die Varianzanalyse (Tabelle 6) weist beide Stufen getrennt aus. Eine Auswertung für K3 liegt für conn_* auf Mittelwertebene bislang nicht vor.

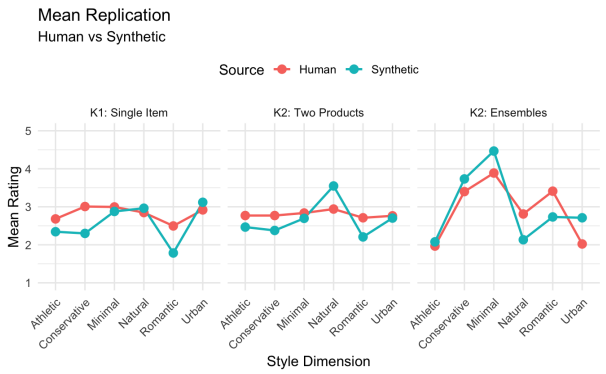


Abbildung 2: Mittelwerte der Stilwahrnehmungsdimensionen nach Datenquelle und Komplexitätsstufe

Anmerkung. Eigene Darstellung.

Insgesamt wird H1 für conn_* nur teilweise unterstützt. Die Ergebnisse zeigen, dass die Fähigkeit zur Mittelwertreplikation nicht global gegeben ist, sondern stark von der jeweiligen Stilsemantik abhängt.

Zusammengefasste Bewertungsmaße. Tabelle 3 stellt die Mittelwertreplikation der drei zusammengefassten Bewertungsmaße dar. Bei liking_mean erreichen alle drei Komplexitätsstufen praktische Äquivalenz; die Differenzen

betragen +0,101 in K1, +0,193 in K2 und +0,078 in K3 (s. Abbildung 3). Damit wird das durchschnittliche Präferenzniveau auf aggregierter Ebene stabil repliziert.

Für wertigkeit_mean wird H1 ebenfalls auf allen drei Komplexitätsstufen unterstützt (s. Abbildung 4). In K1 sind die Mittelwerte nahezu identisch (ΔM = +0,001), bei den Ensembles beträgt die Differenz lediglich −0,093. In K2 ist der klassische t-Test zwar signifikant, der TOST bestätigt jedoch praktische Äquivalenz innerhalb der definierten Grenze.

cons_mean ist ausschließlich in den mehrteiligen Bedingungen verfügbar (s. Abbildung 5). In K2 überschätzen die synthetischen Personas die wahrgenommene Konsistenz um 0,308 Skalenpunkte; der TOST ist mit p_{TOST} = 0,062 nicht signifikant. In K3 beträgt die Mittelwertdifferenz nur −0,019, und praktische Äquivalenz wird bestätigt. H1 wird für cons_mean somit nur teilweise unterstützt.

Tabelle 3: Mittelwertreplikation der zusammengefassten Bewertungsmaße

		M					
Variable	Komplexität	Mensch	Synth.	ΔM	p_t	p_{TOST}	Äquivalenz
liking_mean	K1 (Einzelprodukt)	2,998	3,099	+0,101	0,322	< 0,001	ja
	K2 (Kombination)	2,956	3,148	+0,193	0,187	0,019	ja
	K3 (Ensemble)	3,911	3,989	+0,078	0,572	0,002	ja
wertigkeit_mean	K1 (Einzelprodukt)	2,840	2,841	+0,001	0,987	< 0,001	ja
	K2 (Kombination)	3,091	2,822	−0,269	0,014	0,017	ja
	K3 (Ensemble)	4,059	3,967	−0,093	0,334	< 0,001	ja
cons_mean	K2 (Kombination)	3,281	3,590	+0,308	0,015	0,062	nein
	K3 (Ensemble)	3,848	3,830	−0,019	0,850	< 0,001	ja

Anmerkungen. ΔM = synthetisch minus Mensch. cons_mean ist für K1 nicht definiert, da die wahrgenommene Konsistenz mindestens zwei Produkte voraussetzt.

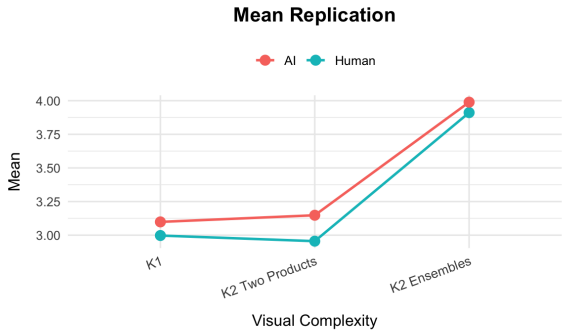


Abbildung 3: Mittelwertreplikation von liking_mean nach Komplexitätsstufe

Anmerkung. Eigene Darstellung.

Stimulusbezogene Analysen zeigen, dass aggregierte Mittelwertäquivalenz erhebliche Abweichungen auf Ebene einzelner Stimuli verdecken kann. So wird MIN_BOTTOM bei liking_mean um etwa 1,052 Skalenpunkte überschätzt, während HIPHOP_BOHO_INKONSISTENT nahezu identische Mittelwerte beider Datenquellen aufweist. Die Mittelwertreplikation fällt auf Ebene der Komplexitätsstufen somit deutlich besser aus als auf Ebene einzelner Stimuli.

Preiserwartung (price_expectation_eur). Da die Preiserwartung in Euro gemessen wird, ist die für die 1–5-Ratings definierte TOST-Grenze nicht sinnvoll übertragbar. Daher wird die Mittelwertreplikation an dieser Stelle deskriptiv anhand der absoluten und der relativen Abweichung beurteilt (s. Tabelle 4). Die relative Abweichung nimmt mit steigender visueller Komplexität deutlich zu: von −2,6 % in K1 über −14,8 % in K2 auf −30,7 % in K3. Somit verschlechtert sich die Replikation des mittleren Preisniveaus mit zunehmender Komplexität erheblich.

Stilerkennung (style_*). Für K1 ist style_k1 kategorial skaliert und daher einem Mittelwert-TOST nicht zugänglich. Stattdessen wird die Trefferquote relativ zum intendierten Zielstil ausgewertet (s. Tabelle 5). Die menschliche

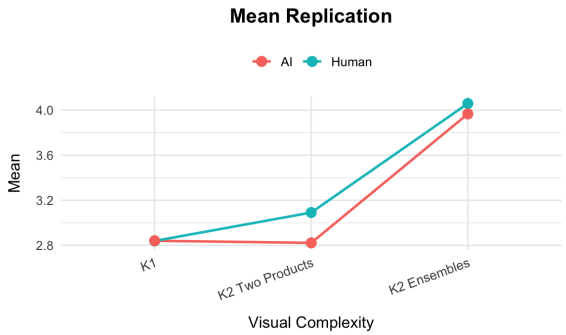


Abbildung 4: Mittelwertreplikation von wertigkeit_mean nach Komplexitätsstufe

Anmerkung. Eigene Darstellung.

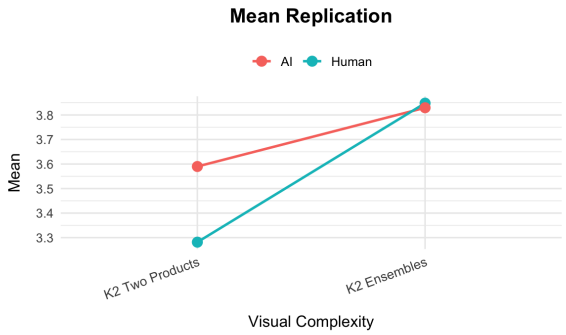


Abbildung 5: Mittelwertreplikation von cons_mean nach Komplexitätsstufe

Anmerkung. Eigene Darstellung.

Tabelle 4: Mittelwertreplikation der Preiserwartung

	M (€)				
Komplexität	Mensch	Synth.	ΔM	rel. Abw.	p_t
K1 (Einzelprodukt)	30,67	29,87	−0,79	−2,6 %	0,887
K2 (Kombination)	62,11	52,89	−9,22	−14,8 %	0,430
K3 (Ensemble)	348,75	241,76	−106,99	−30,7 %	0,059

Anmerkungen. ΔM = synthetisch minus Mensch; rel. Abw. = ΔM bezogen auf den menschlichen Mittelwert. Ein TOST wird nicht berichtet, da die Äquivalenzgrenze der Ratingskalen nicht auf die Euro-Skala übertragbar ist.

Stichprobe erreicht 77,4 % korrekte Zuordnungen (209 von 270), die synthetische Stichprobe 99,3 % (268 von 270). Die höhere Genauigkeit der synthetischen Personas ist jedoch nicht mit einer besseren Replikation menschlicher Antworten gleichzusetzen: Die synthetische Stichprobe folgt nahezu vollständig den experimentell vorgegebenen Kategorien, während die menschlichen Befragten insbesondere an weniger eindeutigen Stilgrenzen mehr Ambiguität zeigen.

Tabelle 5: Genauigkeit der kategorialen Stilerkennung in K1

Stimulus	Mensch	Synthetisch	Differenz
MIN_TOP	95,6 %	100,0 %	+4,4 PP
MIN_BOTTOM	82,2 %	95,6 %	+13,3 PP
BOHO_TOP	62,2 %	100,0 %	+37,8 PP
BOHO_BOTTOM	73,3 %	100,0 %	+26,7 PP
HIPHOP_TOP	66,7 %	100,0 %	+33,3 PP
HIPHOP_BOTTOM	84,4 %	100,0 %	+15,6 PP
Gesamt	77,4 %	99,3 %	+21,9 PP

Anmerkungen. $n = 270$ Zuordnungen je Datenquelle (45 Personen × 6 Stimuli). PP = Prozentpunkte.

In K2 werden HipHop, Minimalismus und Boho auf 1–5-Skalen bewertet. Die mittleren Profile beider Datenquellen weisen grundsätzlich in dieselbe Zielrichtung, die synthetischen Profile fallen jedoch durchgängig extremer aus. Unter der strikten Erkennungsregel erreichen die menschlichen Befragten in K2 66,7 % und in K3 61,1 %, die synthetischen Personas hingegen 95,6 % bzw. 97,8 %. Eine formale Prüfung von H1 für style_k2_* würde separate dimensionale TOSTs erfordern und steht bislang aus.

4.2.2 Replikation der Varianz (H2) [Jiayu Zhao]

Die Varianzbefunde erfordern die Trennung zweier Ebenen. Innerhalb einzelner Stimuli zeigt sich die erwartete Kompression selektiv: Für vier der elf Stimuli liegt die Varianzratio signifikant unter eins ($VR = 0{,}46$ bis $0{,}67$; Brown-Forsythe-Tests $p < 0{,}05$). Betroffen sind beide Minimalismus-Einzelprodukte, die konsistente Minimalismus-Kombination sowie die inkonsistente Kombination. Das inkonsistente Ensemble verfehlt die Signifikanzgrenze knapp ($VR = 0{,}49$; $p = 0{,}060$). Die Boho- und die HipHop-Einzelprodukte sowie das konsistente Ensemble zeigen keine signifikanten Varianzunterschiede ($VR = 1{,}08$ bis $1{,}48$). Durchgängig komprimiert sind die offenen Preisschätzungen ($VR = 0{,}07$; $0{,}08$; $0{,}17$ für K1 bis K3; alle $p_{\mathrm{BF}} < 0{,}01$). Über die Stimuli einer Stufe gepoolt kehrt sich das Bild für K1 und K2 um ($VR = 1{,}45$; beide $p < 0{,}001$): Die Personas ziehen die Stimulusmittelwerte stärker auseinander als die menschlichen Befragten, wodurch die gepoolte Varianz trotz komprimierter Einzelverteilungen wächst. In K3 bleibt die gepoolte Varianz ausgeglichen ($VR = 1{,}06$; $p = 0{,}369$). H2 wird auf dieser Ebene teilweise bestätigt: Varianzkompression tritt konzentriert bei den Minimalismus-Stimuli, der inkonsistenten Kombination und den Preisschätzungen auf (Bisbee et al., 2024), nicht jedoch generell.

Stilwahrnehmung (conn_*). Die Varianzreplikation der Stilwahrnehmungsdimensionen fällt deutlich schwächer aus als die Mittelwertreplikation (s. Tabelle 6). Das mittlere VR beträgt 0,194 in K1, 0,155 in K2 und 0,160 in K3; in allen drei Komplexitätsstufen sind die Brown-Forsythe-Tests über die sechs Dimensionen hinweg signifikant. Die synthetische Stichprobe bildet damit lediglich etwa 15 bis 19 % der menschlichen Varianz ab. H2 wird für conn_* stark unterstützt. Da sich K2 und K3 nur geringfügig unterscheiden, spricht dieser Befund eher für eine konstruktspezifische Response Homogenization als für einen streng linearen Komplexitätseffekt.

Tabelle 6: Varianzreplikation der Stilwahrnehmungsdimensionen (conn_*)

Komplexität	mittleres VR	Brown-Forsythe	Bewertung
K1 (Einzelprodukt)	0,194	alle $p_{\mathrm{BF}} < 0{,}05$	starke Kompression
K2 (Kombination)	0,155	alle $p_{\mathrm{BF}} < 0{,}05$	starke Kompression
K3 (Ensemble)	0,160	alle $p_{\mathrm{BF}} < 0{,}05$	starke Kompression

Anmerkungen. VR = Varianzratio (synthetisch / Mensch), gemittelt über die sechs Dimensionen. Werte < 1 zeigen Varianzkompression an. exakte p_{BF} je Dimension ergänzen

Zusammengefasste Bewertungsmaße und Preiserwartung. Tabelle 7 fasst die Varianzreplikation der *_mean-Maße und der Preiserwartung zusammen. Bei liking_mean zeigt sich kein einheitliches Kompressionsmuster: K1

(VR = 1,088) und K3 (VR = 0,978) liegen nahe am Idealwert eins, lediglich in K2 ist die Varianz signifikant komprimiert (VR = 0,859; p_{BF} = 0,034). H2 wird für liking_mean damit insgesamt nicht bestätigt.

Für wertigkeit_mean wird H2 dagegen sehr deutlich unterstützt. Das VR sinkt von 0,186 in K1 über 0,133 in K2 auf 0,110 in K3; die synthetische Stichprobe repliziert damit nur etwa 11 bis 19 % der menschlichen Varianz. Bei cons_mean liegt in beiden mehrteiligen Bedingungen signifikante Varianzkompression vor, wobei die Ensembles mehr menschliche Varianz bewahren als die Kombinationen. Somit ist die Varianzkompression auch innerhalb der *_mean-Variablen konstruktabhängig.

Die Preiserwartung zeigt auf allen drei Komplexitätsstufen eine ausgeprägte Varianzkompression (VR = 0,126; 0,071; 0,186; alle Brown-Forsythe-Tests signifikant). H2 wird für price_expectation_eur daher stark unterstützt. Die synthetische Stichprobe unterschätzt somit nicht nur das durchschnittliche Preisniveau in komplexeren Bedingungen, sondern bildet zudem die zwischenmenschliche Streuung der Preiserwartungen nur sehr eingeschränkt ab.

Tabelle 7: Varianzreplikation der zusammengefassten Bewertungsmaße und der Preiserwartung

Variable	Komplexität	VR	p_{BF}	Bewertung
liking_mean	K1 (Einzelprodukt)	1,088	0,672	keine Kompression
	K2 (Kombination)	0,859	0,034	signifikante Kompression
	K3 (Ensemble)	0,978	0,066	keine signifikante Kompression
wertigkeit_mean	K1 (Einzelprodukt)	0,186	< 0,001	starke Kompression
	K2 (Kombination)	0,133	< 0,001	starke Kompression
	K3 (Ensemble)	0,110	< 0,001	starke Kompression
cons_mean	K2 (Kombination)	0,193	< 0,001	starke Kompression
	K3 (Ensemble)	0,383	< 0,001	signifikante Kompression
price_expectation_eur	K1 (Einzelprodukt)	0,126	0,007	starke Kompression
	K2 (Kombination)	0,071	0,002	starke Kompression
	K3 (Ensemble)	0,186	0,003	starke Kompression

Anmerkungen. VR = Varianzratio (synthetisch / Mensch); p_{BF} = Brown-Forsythe-Test auf Varianzhomogenität.

Stilerkennung (style_*). Für style_k1 ist eine klassische Varianzratio aufgrund des kategorialen Messniveaus nicht sinnvoll bestimmbar. Dennoch liefert die Verteilung der Klassifikationsentscheidungen deskriptive Hinweise auf geringere Heterogenität: Die synthetische Stichprobe erzielt in fünf der sechs K1-Stimuli 100 % korrekte Zuordnungen, während die menschlichen Antworten je nach Stimulus deutlich stärker streuen (s. Tabelle 5). Auch die K2-Ratings deuten indirekt auf geringere Varianz hin, da die synthetischen Profile stärker polarisiert und näher an den theoretisch intendierten Zielprofilen liegen. Da für style_k2_* bislang keine dimensionsweisen Brown-Forsythe-Tests und VR-Werte vorliegen, wird H2 an dieser Stelle lediglich indirekt über die ausgeprägtere Antwortkonzentration gestützt.

4.2.3 Agreement-Replikation als ergänzende Analyse [Jiayu Zhao]

Die Hypothesen H1 und H2 beziehen sich auf Mittelwerte und Varianzen. Ergänzend wird mit dem Intraklassen-Korrelationskoeffizienten ICC(A,1) geprüft, ob die synthetischen Personas auch individuelle menschliche Antwortmuster absolut replizieren. Insgesamt fällt das Agreement deutlich schwächer aus als die Replikation aggregierter Mittelwerte (s. Tabelle 8).

Tabelle 8: Absolute Übereinstimmung auf Individualebene (ICC(A,1)) nach Konstrukt und Komplexitätsstufe

	ICC(A,1)		
Variable	K1 (Einzelprodukt)	K2 (Kombination)	K3 (Ensemble)
conn_*[a]	0,757	0,751	0,499
liking_mean	0,267	0,057	0,152
wertigkeit_mean	0,164	0,133	0,081
cons_mean	—	Wert	Wert
price_expectation_eur	0,207	0,168	0,240

Anmerkungen. ICC(A,1) = Intraklassen-Korrelation für absolute Übereinstimmung bei Einzelmessungen. cons_mean ist für K1 nicht definiert.
[a] Mittlerer Within-Stimulus-ICC über die sechs conn_*-Dimensionen.

Für liking_mean betragen die ICC-Werte 0,267 in K1, 0,057 in K2 und 0,152 in K3 (s. Abbildung 7); für wertigkeit_mean 0,164, 0,133 und 0,081 (s. Abbildung 8). Bei cons_mean erreicht K2 einen Wert von Wert und K3 von Wert (s. Abbildung 9). Die Preiserwartung weist mit 0,207, 0,168 und 0,240 ebenfalls nur geringe absolute Übereinstimmung auf (s. Abbildung 10).

Eine Ausnahme bilden die sechsdimensionalen conn_*-Profile: Der mittlere Within-Stimulus-ICC beträgt 0,757 in K1 und 0,751 in K2, fällt in K3 jedoch auf 0,499 (s. Abbildung 6). Auf Stimulusebene ist diese Abnahme stark heterogen: EN_KONSISTENT erreicht Wert, EN_INKONSISTENT lediglich Wert.

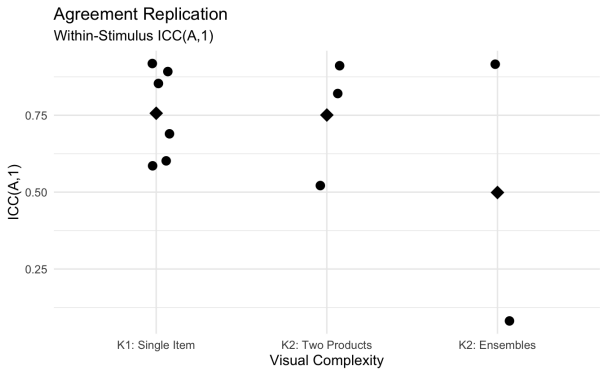


Abbildung 6: Within-Stimulus-ICC(A,1) der conn_*-Profile nach Komplexitätsstufe

Anmerkung. Eigene Darstellung.

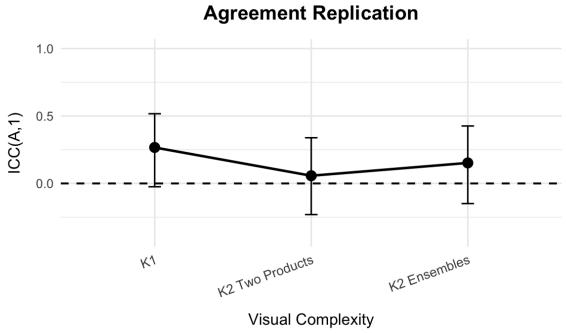


Abbildung 7: ICC(A,1) von liking_mean nach Komplexitätsstufe

Anmerkung. Eigene Darstellung.

Die Ergebnisse verdeutlichen damit eine wiederkehrende Trennung zwischen aggregierter und individueller Replikation. Synthetische Personas können zentrale Mittelwerte und typische Muster teilweise gut replizieren, bilden individuelle Antwortunterschiede jedoch wesentlich weniger zuverlässig ab.

4.2.4 Zusammenfassende Bewertung von H1 und H2 [Jiayu Zhao]

Tabelle 9 stellt die Befunde zu H1 und H2 konstruktweise gegenüber.

H1H1 wird partiell unterstützt. liking_mean und wertigkeit_mean werden auf aggregierter Ebene stabil repliziert, conn_* und cons_mean nur dimensions- bzw. bedingungsabhängig. Bei der Preiserwartung wächst die Abweichung mit der Komplexität.

H2H2 wird überwiegend stark unterstützt. Ausgeprägte Varianzkompression zeigt sich bei conn_*, wertigkeit_mean, cons_mean und price_expectation_eur; liking_mean bildet die Ausnahme. Die Homogenisierung ist damit konstruktabhängig, nicht universell.

4.2.5 Replikation von Subgruppenmustern (H3) [Xiaolan Xu, Franz Wendel]

Die Prüfung von H3 erfolgt zweistufig. Zunächst wird der CVPA-Subgruppeneffekt zwischen beiden Datenquellen verglichen, anschließend wird geprüft, ob die Replikation der Subgruppenstruktur von der Stimuluskomplexität

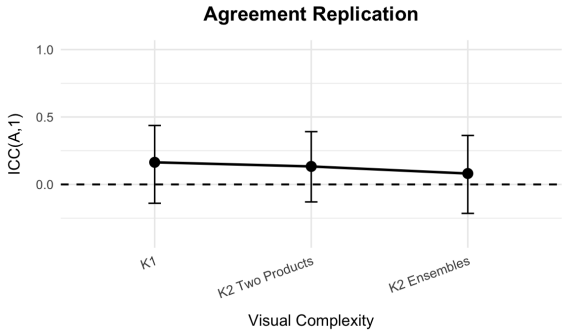


Abbildung 8: ICC(A,1) von wertigkeit_mean nach Komplexitätsstufe

Anmerkung. Eigene Darstellung.

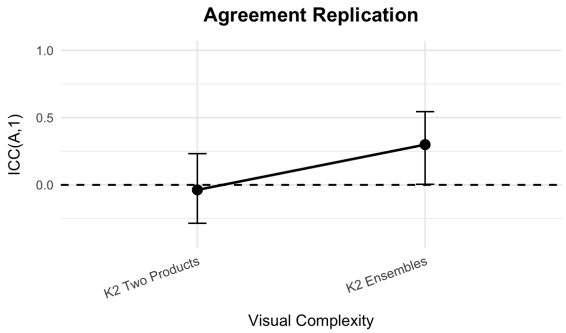


Abbildung 9: ICC(A,1) von cons_mean nach Komplexitätsstufe

Anmerkung. Eigene Darstellung.

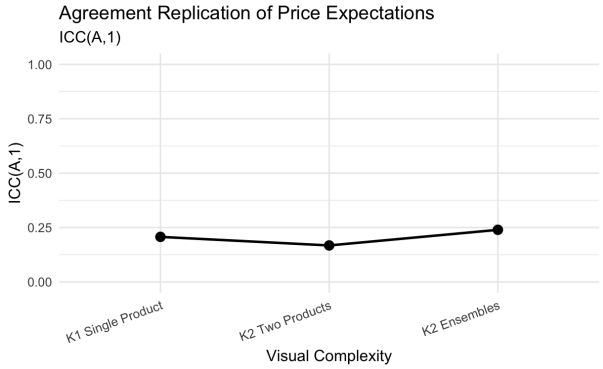


Abbildung 10: ICC(A,1) von price_expectation_eur nach Komplexitätsstufe

Anmerkung. Eigene Darstellung.

Tabelle 9: Zusammenfassende Bewertung der Hypothesen H1 und H2

Variable	H1	H2	Zentrale Schlussfolgerung
conn_*	teilweise	stark	Mittelwertreplikation dimensionsabhängig; romantische Konnotation systematisch unterschätzt; starke Varianzkompression.
liking_mean	ja	nein	Mittelwerte auf allen drei Komplexitätsstufen äquivalent; Varianzkompression nur in K2.
wertigkeit_mean	ja	stark	Mittelwerte auf allen Stufen äquivalent; VR sinkt von 0,186 auf 0,110.
cons_mean	teilweise	ja	K2 nicht äquivalent; beide mehrteiligen Bedingungen zeigen Varianzkompression.
price_expectation_eur	n. a.	stark	Unterschätzung des Preisniveaus steigt mit der Komplexität; alle VR deutlich < 1.
style_k1	n. a.	n. a.	Synthetische Stichprobe klassifiziert deutlich konsistenter; geringere kategoriale Antwortheterogenität.
style_k2_*	offen	indirekt	Profilrichtung stimmt überein, synthetische Ratings sind jedoch extremer und homogener.

Anmerkungen. ja = Hypothese unterstützt; teilweise = teilweise unterstützt; stark = stark unterstützt; nein = nicht unterstützt; indirekt = nur indirekt gestützt; offen = Prüfung steht aus; n. a. = Verfahren aufgrund des Messniveaus nicht anwendbar.

abhängt.

Subgruppeneffekt der CVPA [Franz Wendel] Für die Analyse der Subgruppen wird primär die Centrality of Visual Product Aesthetics (CVPA) berücksichtigt. Die Werte liegen beiden Datenquellen identisch zugrunde, da sie Bestandteil der gespiegelten Personaprofile sind. Es werden zwei Gruppen über einen Median-Split bei 4,0 gebildet (hohe Ausprägung: $n = 22$; niedrige Ausprägung: $n = 31$). Tabelle 10 stellt die Befunde gegenüber.

In der menschlichen Stichprobe zeigt sich der erwartete Subgruppenunterschied: Befragte mit hoher CVPA bewerten die Stimuli positiver ($M = 3{,}46$ vs. $M = 2{,}87$; Welch-Test $t(49{,}3) = 3{,}99$, $p < 0{,}001$, $d = 1{,}08$). Der Zusammenhang beträgt $r = 0{,}36$ ($p = 0{,}009$). In der synthetischen Stichprobe ist dieser Zusammenhang nicht signifikant ($M = 3{,}29$ vs. $M = 3{,}25$; $t(43{,}4) = 0{,}33$, $p = 0{,}741$; $r = 0{,}09$, $p = 0{,}526$), obwohl der CVPA-Wert im Persona-Prompt übergeben wurde. Die Interaktion Datenquelle × CVPA-Gruppe ist signifikant ($t(45{,}2) = -2{,}76$, $p = 0{,}008$): Die synthetischen Personas überschätzen die Präferenzen der Gruppe mit niedriger CVPA ($\Delta = 0{,}37$) und unterschätzen jene der Gruppe mit hoher CVPA ($\Delta = -0{,}16$).

Dasselbe Muster zeigt sich deskriptiv für die Need for Uniqueness (Mensch: $r = 0{,}26$, $p = 0{,}059$; synthetisch: $r = 0{,}07$, $p = 0{,}604$). Die Kulturkreisanalyse (Asien: $n = 42$; Nicht-Asien: $n = 11$) liefert weder für die menschliche ($p = 0{,}456$) noch für die synthetische Stichprobe ($p = 0{,}201$) signifikante Befunde. Zudem ist die Variable Kulturkreis inhärent stark mit der Erhebungssprache korreliert, weshalb sich Gruppen- und Spracheffekte nur eingeschränkt getrennt untersuchen lassen. Für das CVPA-Subgruppenmuster wird H3 auf dieser Grundlage gestützt: Der in der menschlichen Stichprobe nachgewiesene Subgruppeneffekt wird von den synthetischen Personas nicht wiedergegeben.

Tabelle 10: Replikation des CVPA-Subgruppenmusters im personengemittelten Liking-Index (H3)

CVPA-Gruppe	n	Mensch M (SD)	Synthetisch M (SD)	Δ (S − M)
hoch (> 4,0)	22	3,46 (0,48)	3,29 (0,52)	−0,16
niedrig (≤ 4,0)	31	2,87 (0,57)	3,25 (0,49)	+0,37
Subgruppeneffekt		$t(49{,}3) = 3{,}99$ $p < 0{,}001$	$t(43{,}4) = 0{,}33$ $p = 0{,}741$	

Anmerkungen. $N = 53$ Paare; Median-Split der CVPA (Bloch et al., 2003) bei 4,0. Welch-Tests; Δ = Mittel der personenweisen Differenzen (synthetisch minus Mensch); Interaktion Datenquelle × CVPA-Gruppe über die gepaarten Differenzen: $t(45{,}2) = -2{,}76$, $p = 0{,}008$.

Einfluss der Stimuluskomplexität [Xiaolan Xu] Vor dem Hintergrund bisheriger Forschung zu synthetischen Stichproben (Argyle et al., 2023; Bisbee et al., 2024) wird ergänzend untersucht, ob sich Subgruppenmuster bei höherer Stimuluskomplexität besser replizieren lassen. Für jede der elf Stimulusbedingungen werden in den Human- und

den synthetischen Daten getrennte Drei-Cluster-Lösungen mit dem K-Means-Verfahren geschätzt ($k = 3$; Hartigan & Wong, 1979). Anschließend werden die Clusterlabels mithilfe des ungarischen Algorithmus einander optimal zugeordnet (Kuhn, 1955). Für den Vergleich stehen sechs Einzelstimuli, drei Kombinationsstimuli und zwei Ensemble-Stimuli zur Verfügung; jede Bedingung umfasst 45 gepaarte Beobachtungen.

Zur Beurteilung werden fünf Kennwerte herangezogen. Matching Accuracy sowie Cohens κ (Cohen, 1960) erfassen die Übereinstimmung der individuellen Clusterzuordnung. Der Adjusted Rand Index (ARI) bewertet die Ähnlichkeit der gesamten Clusterpartition (Hubert & Arabie, 1985; Chacón, 2021). Die Total Variation Distance (TVD) beschreibt Unterschiede in den Subgruppengrößen (Gibbs & Su, 2002), während der skalierte Centroid Mean Absolute Error (sCMAE) Abweichungen der Zentroidprofile erfasst (Fränti et al., 2014; Willmott & Matsuura, 2005). Höhere Werte sind bei Matching Accuracy, Cohens κ und ARI günstiger; bei TVD und sCMAE zeigen niedrigere Werte eine bessere Replikation an (s. Abbildung 11).

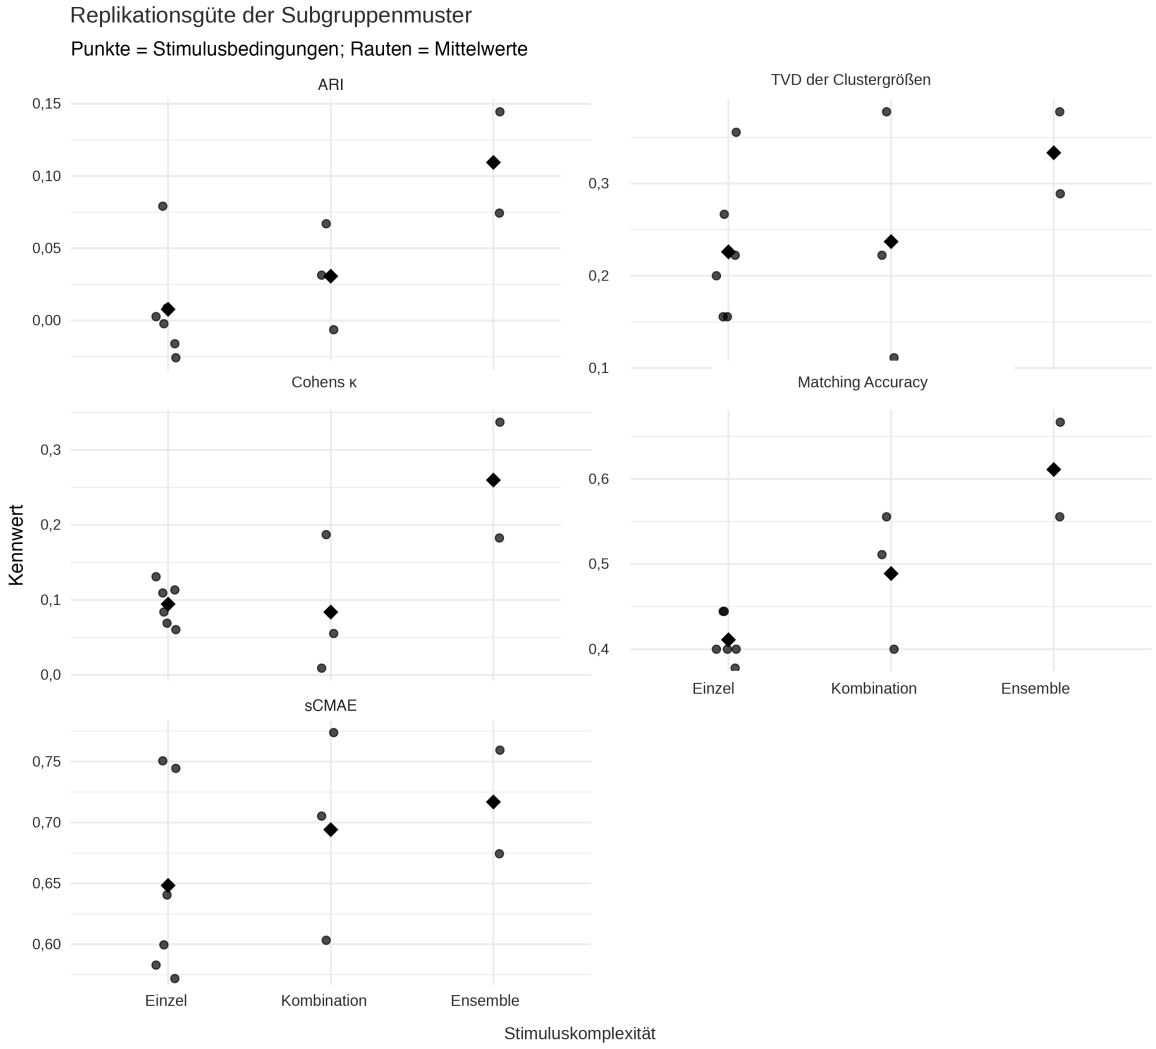


Abbildung 11: Replikationsgüte der Subgruppenmuster in Abhängigkeit von der Stimuluskomplexität

Anmerkung. Eigene Darstellung. Graue Punkte stehen für einzelne Stimulusbedingungen, schwarze Rauten für die Mittelwerte der jeweiligen Komplexitätsstufe. Höhere Werte bedeuten bei Matching Accuracy, Cohens κ und ARI eine bessere Replikation; bei TVD und sCMAE gilt das Gegenteil.

Deskriptive Ergebnisse. Die Matching Accuracy steigt mit der Stimuluskomplexität von 0,411 bei den Einzelstimuli über 0,489 bei den Kombinationsstimuli auf 0,611 bei den Ensemble-Stimuli. Die erwarteten Zufallstrefferquoten liegen bei 0,349, 0,442 und 0,477 (s. Abbildung 12). Der Abstand zum Zufallsniveau beträgt damit +0,062, +0,047 und +0,134. Er zeigt keinen vollständig linearen Verlauf, ist bei den Ensemble-Stimuli jedoch am größten. Die direkte Übereinstimmung der individuellen Clusterzuordnung ist somit bei den Ensemble-Stimuli am höchsten.

Bei den weiteren Kennwerten zeigt sich kein einheitlicher Vorteil höherer Stimuluskomplexität (s. Tabelle 11). Für die Ensemble-Stimuli liegen Cohens κ (0,260) und der ARI (0,109) zwar über den Werten der beiden anderen Stufen,



Abbildung 12: Beobachtete Matching Accuracy und erwartete Zufallstrefferquote nach Stimuluskomplexität

Anmerkung. Eigene Darstellung. In Klammern steht die Zahl der Stimulusbedingungen je Komplexitätsstufe. Der Nettozuwachs entspricht der beobachteten Matching Accuracy abzüglich der erwarteten Zufallstrefferquote.

insgesamt bleiben beide Kennwerte jedoch niedrig. Gleichzeitig steigt die TVD von 0,226 bei den Einzelstimuli auf 0,333 bei den Ensemble-Stimuli, der sCMAE erhöht sich von 0,648 auf 0,717. Da bei TVD und sCMAE niedrigere Werte günstiger sind, verbessern sich weder die Übereinstimmung der Subgruppengrößen noch die Ähnlichkeit der Zentroidprofile. Insgesamt zeigt sich damit vor allem ein Vorteil bei der individuellen Zuordnung.

Tabelle 11: Kennwerte der Subgruppenreplikation mit 95-%-Bootstrap-Konfidenzintervallen nach Stimuluskomplexität

Kennwert	Einzelstimuli (n = 6)	Kombinationsstimuli (n = 3)	Ensemble-Stimuli (n = 2)
Matching Accuracy ↑	0,411 [0,341; 0,507]	0,489 [0,385; 0,615]	0,611 [0,378; 0,645]
Cohens κ ↑	0,094 [0,010; 0,178]	0,084 [−0,023; 0,208]	0,260 [0,026; 0,374]
ARI ↑	0,008 [−0,011; 0,092]	0,031 [−0,008; 0,127]	0,109 [−0,016; 0,226]
TVD der Clustergrößen ↓	0,226 [0,159; 0,333]	0,237 [0,111; 0,349]	0,333 [0,100; 0,356]
sCMAE ↓	0,648 [0,648; 0,816]	0,694 [0,651; 0,826]	0,717 [0,623; 0,847]

Anmerkungen. In eckigen Klammern stehen die 95-%-Bootstrap-Konfidenzintervalle. n bezeichnet die Zahl der Stimulusbedingungen je Komplexitätsstufe. ↑ = höhere Werte bedeuten eine bessere Replikation; ↓ = niedrigere Werte bedeuten eine bessere Replikation.

Inferenzstatistische Prüfung. Ein personenbezogener Friedman-Test (Friedman, 1937) ergibt für $n = 45$ einen Unterschied in der Matching Accuracy zwischen den drei Komplexitätsstufen, $\chi^2(2) = 9{,}37$, $p = 0{,}009$, Kendalls $W = 0{,}104$. Der Effekt ist als klein einzustufen. Paarweise Wilcoxon-Vorzeichen-Rang-Tests mit Holm-Korrektur (Holm, 1979; Wilcoxon, 1945) zeigen höhere Werte für die Ensemble-Stimuli als für die Einzelstimuli ($p = 0{,}007$) und die Kombinationsstimuli ($p = 0{,}046$). Zwischen Einzel- und Kombinationsstimuli besteht kein signifikanter Unterschied ($p = 0{,}331$). In einer Sensitivitätsanalyse bleibt der Gesamteffekt nach Ausschluss der inkonsistenten Stimulusbedingungen signifikant, $\chi^2(2) = 8{,}09$, $p = 0{,}017$. Da die Ensemble-Stufe danach nur noch eine Bedingung umfasst, ist dieses Ergebnis jedoch vorsichtig zu interpretieren.

Die Bootstrap-Analysen (Efron, 1979) schränken diese Aussage ein. In allen drei Komplexitätsstufen schließen die 95-%-Konfidenzintervalle des ARI den Wert null ein (s. Abbildung 13). Gleiches gilt für alle 15 Konfidenzintervalle der paarweisen Unterschiede zwischen den Komplexitätsstufen (drei Stufenvergleiche × fünf Kennwerte). Zudem

besteht die Ensemble-Stufe nur aus zwei Stimulusbedingungen, sodass die Schätzungen vergleichsweise unsicher sind. Die signifikanten Ergebnisse stammen damit aus der personenbezogenen Analyse; die auf Stimulusbedingungen beruhenden Bootstrap-Analysen bestätigen keinen stabilen, allgemeinen Vorteil höherer Stimuluskomplexität für die gesamte Subgruppenstruktur.

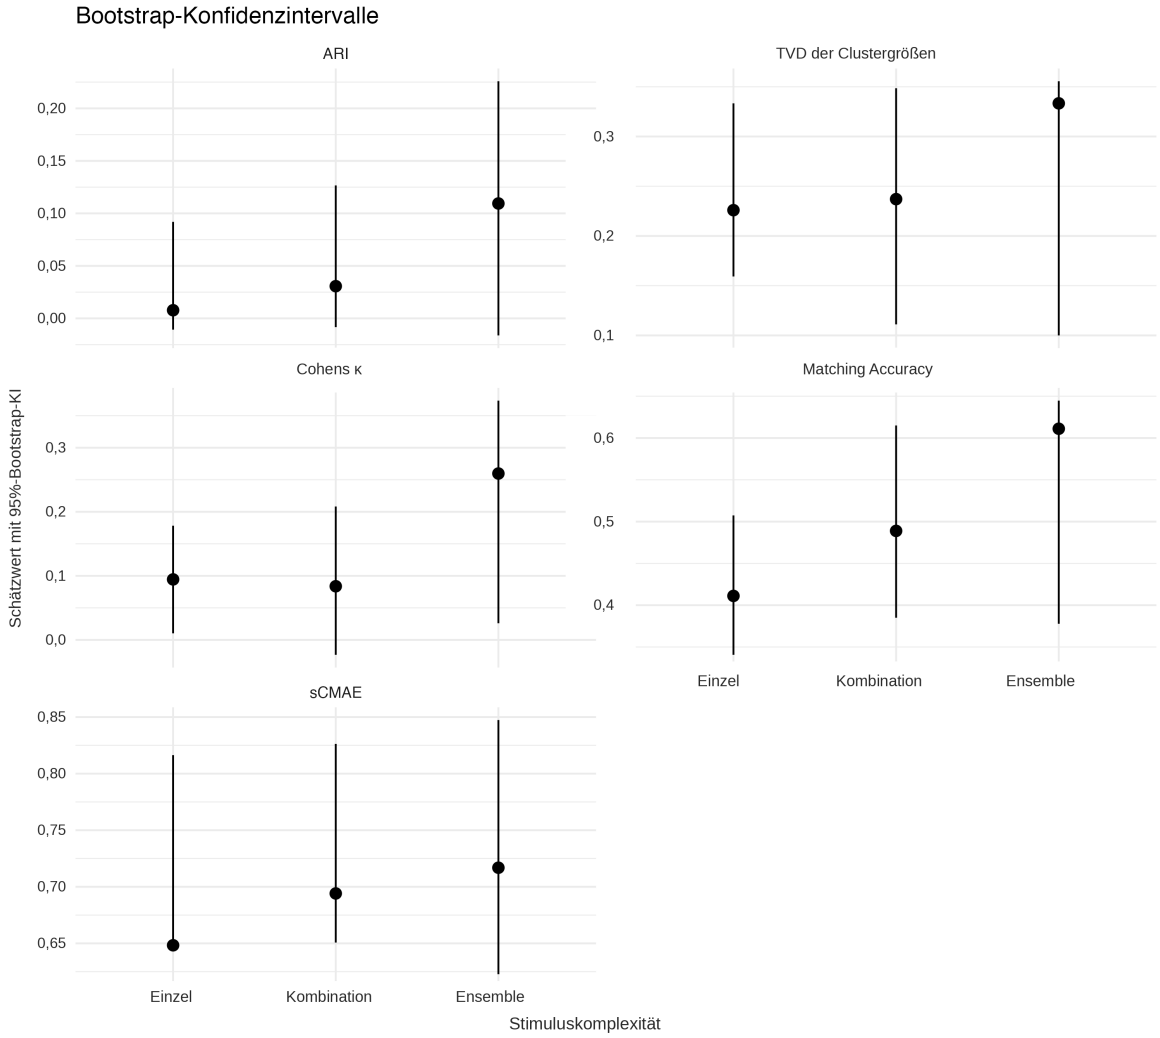


Abbildung 13: Bootstrap-Konfidenzintervalle der Replikationskennwerte nach Stimuluskomplexität

Anmerkung. Eigene Darstellung. Die Punkte zeigen die Mittelwerte, die Linien die zugehörigen 95-%-Bootstrap-Konfidenzintervalle. Bei ARI, Cohens κ und Matching Accuracy sind höhere Werte günstiger, bei TVD und sCMAE niedrigere. Die Ordinaten sind für jeden Kennwert separat skaliert.

H3 wird teilweise unterstützt. Der CVPA-Subgruppeneffekt der menschlichen Stichprobe wird nicht repliziert; höhere Stimuluskomplexität verbessert lediglich die individuelle Clusterzuordnung, nicht die gesamte Subgruppenstruktur.

4.3 Vergleich der eigenständigen Datenanalyse mit dem ChatGPT Data Analyst [Xiaolan Xu]

In diesem Abschnitt wird die herkömmliche, eigenständige Datenanalyse in RStudio den Ergebnissen des *ChatGPT Data Analyst* gegenübergestellt. Ziel ist es, systematisch zu evaluieren, inwieweit die künstliche Intelligenz in der Lage ist, zentrale statistische Kennzahlen wie Mittelwerte und Varianzen sowie komplexere Subgruppenmuster aus den Rohdaten zuverlässig zu reproduzieren.

4.3.1 Replikation der Mittelwerte

Bei den Mittelwerten zeigen die Ergebnisse aus RStudio und dem *Data Analyst* eine sehr hohe Übereinstimmung. Für K1 lassen sich die Human- und die synthetischen Mittelwerte der sechs conn_*-Variablen sowie von liking_mean, wertigkeit_mean und price_expectation_eur in beiden Analysen nahezu identisch reproduzieren. Beispielsweise beträgt conn_athletisch in beiden Auswertungen 2,681 vs. 2,344, conn_roma 2,496 vs. 1,785, liking_mean 2,998 vs.

3,099, wertigkeit_mean 2,840 vs. 2,841 und die Preiserwartung 30,666 vs. 29,872 €. Dies zeigt, dass die auf Basis der Rohdaten berechneten Mittelwerte mit den RStudio-Ergebnissen übereinstimmen.

Hinsichtlich der Replikationsqualität der menschlichen Mittelwerte durch die synthetische Stichprobe zeigt sich für K1 die geringste Abweichung bei wertigkeit_mean ($\Delta M = +0{,}001$). Auch liking_mean ($\Delta M = +0{,}101$), conn_natur ($\Delta M = +0{,}115$) und conn_reduziert ($\Delta M = -0{,}119$) werden relativ genau repliziert. Größere Abweichungen treten dagegen bei conn_roma ($\Delta M = -0{,}711$) und conn_konservativ ($\Delta M = -0{,}707$) auf. Für K2 zeigen conn_natur ($\Delta M = +0{,}093$), conn_konservativ ($\Delta M = -0{,}102$), conn_athletisch ($\Delta M = -0{,}138$) und liking_mean ($\Delta M = +0{,}147$) eine vergleichsweise gute Übereinstimmung, während conn_roma erneut deutlich unterschätzt wird ($\Delta M = -0{,}573$). Die größte absolute Abweichung zeigt sich bei der Preiserwartung, welche um etwa 48,33 € niedriger eingeschätzt wird als von den menschlichen Befragten (s. Abbildung 14).

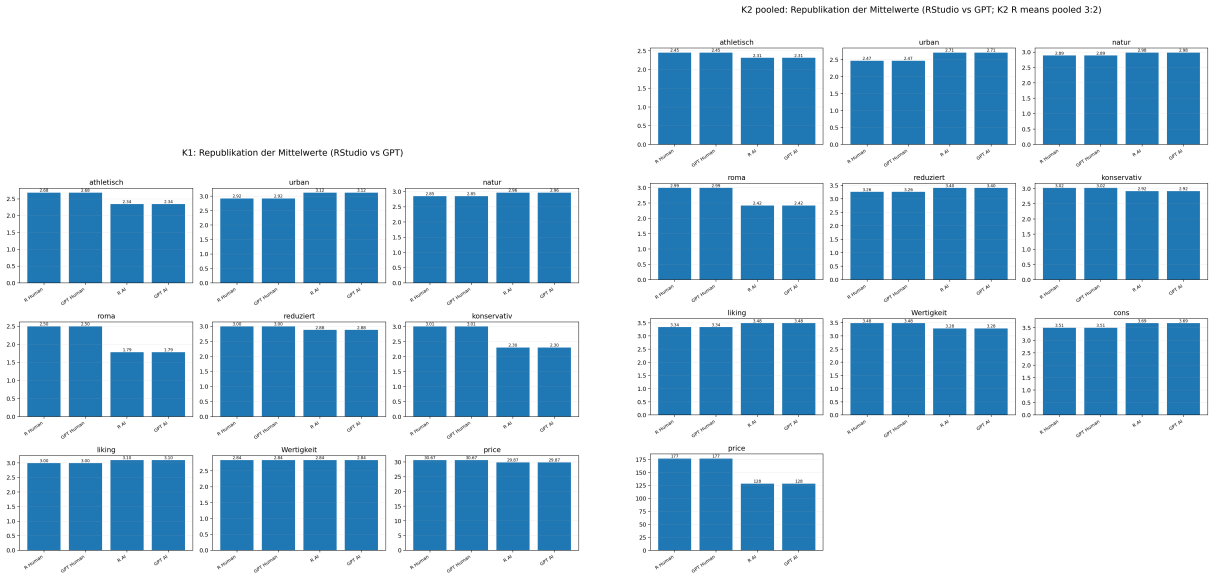


Abbildung 14: Replikation der Mittelwerte (RStudio vs. ChatGPT Data Analyst)

Anmerkung. Eigene Darstellung. K1 und K2 gepoolt (R-Mittelwerte im Verhältnis 3:2). Die Achsenbeschriftungen R Human, GPT Human, R AI und GPT AI kennzeichnen Datenquelle und Auswertungsumgebung.

4.3.2 Replikation der Varianz

Im Gegensatz zu den Mittelwerten bestehen bei der Varianz deutlichere Unterschiede zwischen den RStudio- und den GPT-Ergebnissen. Diese Unterschiede sind primär nicht auf Berechnungsfehler, sondern auf unterschiedliche statistische Aggregationsebenen zurückzuführen. Der *Data Analyst* berechnet die gepoolte Varianz auf Basis aller Rohbeobachtungen und berücksichtigt damit sowohl die Variation innerhalb als auch zwischen den Stimuli. Die RStudio-Analyse verwendet dagegen einen stärker stimulussensitiven Ansatz, welcher insbesondere bei den conn_*-Variablen die Streuung der Bewertungen innerhalb der einzelnen Stimuli berücksichtigt. Die Varianzergebnisse hängen daher stark von der gewählten Aggregationsebene ab.

Für K2 zeigt sich ein vergleichbares Muster. Für den deskriptiven Vergleich mit dem gepoolten GPT-Wert werden die RStudio-Ergebnisse für Kombinationen und Ensembles im Verhältnis 3:2 gewichtet. Die VR-Werte betragen für conn_athletisch 0,117 (RStudio) vs. 0,901 (GPT), für conn_natur 0,142 vs. 0,790, für conn_reduziert 0,104 vs. 1,236 und für conn_konservativ 0,131 vs. 0,963. Bei liking_mean ist der Unterschied geringer (0,907 vs. 1,233), während price_expectation_eur bei beiden Methoden deutlich unter eins liegt (0,117 vs. 0,235). Die gewichteten K2-Werte dienen dabei ausschließlich dem deskriptiven Vergleich und entsprechen keiner neu berechneten gepoolten Varianz (s. Abbildung 15).

Zusammenfassend sind die Ergebnisse zur Replikation der Mittelwerte zwischen RStudio und GPT sehr robust, während die Varianzreplikation stärker von der statistischen Aggregationsebene abhängt. Bei Anwendung des stimulussensitiven RStudio-Ansatzes zeigt sich eine deutlich stärkere Varianzkompression, insbesondere bei den conn_*-Dimensionen, der Wertigkeit und der Preiserwartung. Dies deutet darauf hin, dass synthetische Respondenten durchschnittliche menschliche Bewertungen relativ gut reproduzieren können, die Heterogenität menschlicher Reaktionen jedoch nur eingeschränkt abbilden.

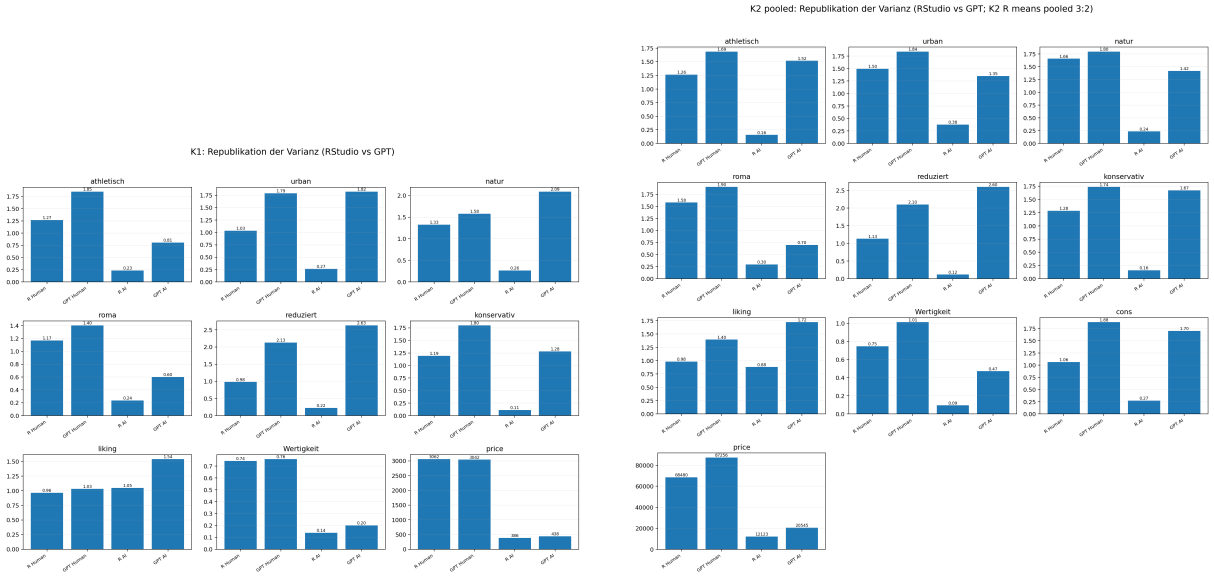


Abbildung 15: Replikation der Varianz (RStudio vs. ChatGPT Data Analyst)

Anmerkung. Eigene Darstellung. K1 und K2 gepoolt (R-Mittelwerte im Verhältnis 3:2). Die Achsenbeschriftungen R Human, GPT Human, R AI und GPT AI kennzeichnen Datenquelle und Auswertungsumgebung.

4.3.3 Replikation der Subgruppenmuster

Zur Beurteilung der Replikation der Subgruppenmuster werden die Ergebnisse der eigenständig durchgeführten R-Auswertung (s. Abbildung 11) den Ergebnissen der Analyse mit dem *ChatGPT Data Analyst* gegenübergestellt (s. Abbildung 16). Die Matching Accuracy steigt in beiden Auswertungen von den Einzel- über die Kombinations- zu den Ensemble-Stimuli. Für Kombinations- und Ensemble-Stimuli stimmen die Ergebnisse überein; bei den Einzelstimuli ist die Abweichung gering. Auch Cohens κ und der ARI sind bei den Ensemble-Stimuli am höchsten. Der sCMAE nimmt dagegen leicht zu, was auf eine etwas geringere Übereinstimmung der Clusterzentren hindeutet.

Die Bootstrap-Konfidenzintervalle ergeben ebenfalls ein vergleichbares Gesamtbild (s. Abbildung 17). Kleinere Abweichungen sind aufgrund der zufälligen Initialisierung des K-Means-Verfahrens und des Bootstrap-Verfahrens zu erwarten. Insgesamt bestätigt die ChatGPT-Analyse die zentralen Ergebnisse der R-Auswertung.

4.4 Zusammenfassung der zentralen Ergebnisse [Franz Wendel]

Abschließend werden die Befunde hypothesenweise konsolidiert.

H1 (Mittelwerte). Die Replikation der Mittelwerte gelingt auf aggregierter Ebene weitgehend, jedoch nicht konstruktunabhängig. Die zusammengefassten Bewertungsmaße liking_mean und wertigkeit_mean erreichen auf allen drei Komplexitätsstufen praktische Äquivalenz, während die Stilwahrnehmungsdimensionen dimensionsabhängige Abweichungen aufweisen und die romantische Konnotation systematisch unterschätzt wird ($\Delta M = -0{,}711$ in K1; $\Delta M = -0{,}573$ in K2). Bei der Preiserwartung nimmt die relative Unterschätzung mit steigender visueller Komplexität von $-2{,}6\,\%$ auf $-30{,}7\,\%$ zu. H1 wird somit teilweise bestätigt.

H2 (Varianz). Die Varianzkompression synthetischer Antworten ist über die meisten Konstrukte hinweg deutlich nachweisbar. Für conn_*, wertigkeit_mean, cons_mean und price_expectation_eur liegen die Varianzratios zwischen 0,07 und 0,38; lediglich liking_mean bildet mit Werten nahe eins die Ausnahme. Ergänzend zeigt die Agreement-Analyse, dass die absolute Übereinstimmung auf Individualebene mit ICC-Werten von 0,06 bis 0,27 deutlich hinter der Replikation aggregierter Mittelwerte zurückbleibt. H2 wird somit überwiegend bestätigt, wobei die Homogenisierung als konstruktabhängiger und nicht als universeller Effekt einzustufen ist.

H3 (Subgruppen). Der Subgruppeneffekt der mediangeteilten CVPA-Gruppen wird durch die synthetischen Daten nicht repliziert, obwohl der CVPA-Wert im Persona-Prompt übergeben wurde. Die clusterbasierte Analyse zeigt lediglich einen begrenzten Vorteil der Ensemble-Stimuli bei der individuellen Clusterzuordnung, nicht jedoch eine generell bessere Replikation der gesamten Subgruppenstruktur. H3 wird somit teilweise bestätigt. Die Untersuchung weiterer Subgruppen ist aufgrund der begrenzten Stichprobengröße Gegenstand zukünftiger Forschung (s. Abschnitt 5.3).

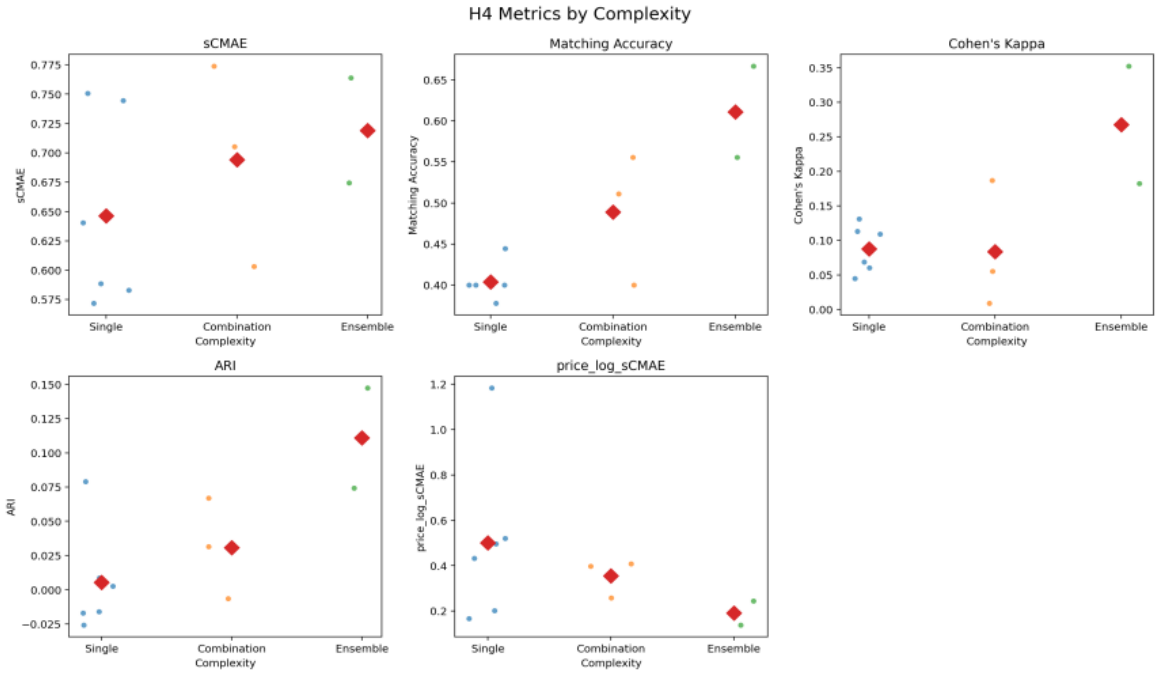


Abbildung 16: Replikationskennwerte nach Stimuluskomplexität (ChatGPT-Analyse)

Anmerkung. Eigene Darstellung. Punkte zeigen die einzelnen Stimulusbedingungen, Rauten die Mittelwerte der Komplexitätsstufen. Niedrigere Fehlerwerte sowie höhere Accuracy-, κ- und ARI-Werte bedeuten eine bessere Übereinstimmung.

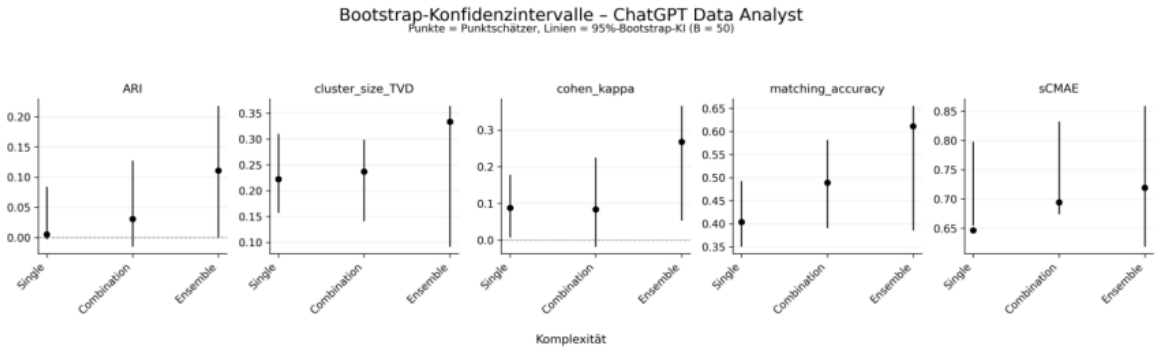


Abbildung 17: Bootstrap-Konfidenzintervalle der Replikationskennwerte (ChatGPT-Analyse)

Anmerkung. Eigene Darstellung. Punkte zeigen die Punktschätzungen, Linien die 95-%-Bootstrap-Konfidenzintervalle bei $B = 50$.

5 Diskussion

5.1 Interpretation der Ergebnisse [Xiaolan Xu]

Die Auswertung zeigt, inwieweit synthetische Personas menschliche Antworten auf symbolisch konnotierte visuelle Stimuli reproduzieren können. Die Ergebnisse lassen sich entlang der drei statistischen Prüfungsebenen wie folgt strukturieren:

1. Replikation der Mittelwerte (H1)

- **Aggregierte Ebene:** Die KI repliziert das durchschnittliche Präferenzniveau (Liking) und die wahrgenommene Wertigkeit vergleichsweise zuverlässig. Für diese Konstrukte liegt eine praktische Äquivalenz zwischen realen und synthetischen Daten vor.
- **Stimulusebene:** Diese aggregierte Äquivalenz verdeckt jedoch signifikante Abweichungen bei einzelnen Bildern. Bestimmte Stilwahrnehmungen, wie die romantische Konnotation, werden von der KI systematisch unterschätzt. Bei offenen Preisschätzungen sinkt die Genauigkeit mit steigender visueller Komplexität der Stimuli stark ab.
- **Individualebene:** Trotz der vergleichsweise guten Übereinstimmung aggregierter Mittelwerte ist die absolute Übereinstimmung auf Personenebene deutlich schwächer. Niedrige Intraklassenkorrelationen (ICC) zeigen, dass die KI zwar zentrale durchschnittliche Muster erfasst, die individuellen Antwortmuster der jeweils gespiegelten Person jedoch nur eingeschränkt reproduziert.

2. Replikation der Varianz (H2)

- **Aggregierte Ebene:** Es zeigt sich eine deutliche, jedoch konstruktabhängige Varianzkompression. Je nach Variable bilden die synthetischen Daten nur einen begrenzten Anteil der menschlichen Varianz ab, besonders bei den Stilkonnotationen, der Wertigkeit, der Stimmigkeit und der Preiserwartung. Für *liking_mean* zeigt sich dagegen keine durchgängige Varianzkompression.
- **Stimulusebene:** Innerhalb einzelner Stimuli zeigt sich häufig eine Varianzkompression. Gleichzeitig differenziert die KI stärker zwischen verschiedenen Stimuli. Werden diese gemeinsam gepoolt, kann die Gesamtvarianz daher – wie bei K1 und K2 – trotz komprimierter Einzelverteilungen ansteigen.
- **Individualebene:** Die geringere Streuung deutet auf eine eingeschränkte Abbildung menschlicher Heterogenität hin. Dies lässt sich als stärkere Orientierung der Personas an prototypischen Antwortmustern interpretieren.

3. Replikation der Subgruppenmuster (H3)

- **Subgruppenebene:** Der CVPA-bezogene Subgruppeneffekt wird von den synthetischen Personas nicht repliziert. Während Befragte mit hoher Centrality of Visual Product Aesthetics (CVPA) die Stimuli in der menschlichen Stichprobe positiver bewerten, verschwindet dieser Unterschied in der synthetischen Stichprobe weitgehend. Die KI überschätzt dabei die Präferenzen der Gruppe mit niedriger CVPA und unterschätzt jene mit hoher CVPA.
- **Stimulusebene:** Mit höherer Stimuluskomplexität zeigt sich ein begrenzter Vorteil bei der individuellen Clusterzuordnung, insbesondere bei den Ensemble-Stimuli. Dieser Vorteil reicht jedoch nicht aus, um eine generell bessere Replikation der gesamten Subgruppenstruktur nachzuweisen.

5.2 Implikationen für den Einsatz synthetischer Personas in der Marktforschung [Xiaolan Xu]

Die Befunde verdeutlichen, dass synthetische Daten („Silicon Samples“) menschliche Befragungsdaten derzeit nicht vollständig ersetzen können. Sie eignen sich vor allem als heuristisches Instrument in frühen und explorativen Forschungsphasen, etwa für Stimulus-Screenings, grobe Richtungsentscheidungen oder die Einschätzung durchschnittlicher Präferenzmuster. Für komplexere Marktforschungsziele wie detaillierte Zielgruppensegmentierungen, belastbare Preisschätzungen oder die Analyse psychologischer Subgruppen sind sie dagegen nur eingeschränkt geeignet. Insbesondere die konstruktabhängige Varianzkompression und die schwache Replikation individueller sowie subgruppenspezifischer Unterschiede können zu einer Überschätzung der Homogenität von Konsumentenurteilen führen. Synthetische Personas sollten daher als ergänzendes, nicht als ersetzendes Instrument eingesetzt werden.

5.3 Limitationen und zukünftiger Forschungsbedarf [Franz Wendel]

Mehrere Einschränkungen begrenzen die Aussagekraft. In Bezug auf die Stichprobe, lässt sich kritisieren, dass diese vergleichweise klein und demografisch homogen ist. Dazu kommt dass die Personenauswahl nicht randomisiert ist. Weiterhin ist die kulturelle Subgruppe nicht ausgeglichen (42 vs. 11). Die externe Validität ist dadurch begrenzt (Henrich et al., 2010). Die gespiegelten Personas erhalten diese Schieflage ebenfalls. Übersetzungsbedingte Formulierungsunterschiede wirken als systematischer Messfehler und erhört somit die Varianz. Zudem unterscheiden sich Antwortstile (Akquieszenz, Tendenz zu Extremantworten, Tendenz zur Mitte) systematisch zwischen Sprachen und Kulturen (Bogner & Landrock, 2015). In Bezug auf die Datenbereinigung lässt sich kritisieren, dass kein eindeutiger Schwellenwert der zum Ausschluss durch Datenbereinigung fürht. Das K2-Set ist unvollständig balanciert (keine konsistente HipHop-Paarung). In Bezug auf die synthetische Datenerhebung wurde keine Sensitivität auf Promts und verschiedene Modelle untersucht. Zukünftige Forschung sollte die folgenden Punkte adressieren: Robustheitsanalysen über mehrere Modelle und Prompts und die Prüfung der Replikationsgüte an größeren, sprachlich ausbalancierten Stichproben.

5.4 Fazit [Xiaolan Xu]

In der visuellen Marktforschung zeigen synthetische Personas insbesondere bei ausgewählten aggregierten Kennwerten eine brauchbare Replikationsgüte. Durchschnittliche Präferenz- und Wertigkeitsurteile werden teilweise zuverlässig reproduziert, während sich bei Varianz, individuellen Antwortmustern und Subgruppen deutliche Einschränkungen zeigen. Die Ergebnisse verdeutlichen damit eine klare Grenze zwischen der Replikation aggregierter Bewertungsmuster und der Abbildung individueller sowie subgruppenspezifischer Heterogenität. Silicon Samples können reale Befragungen insbesondere in frühen Forschungsphasen sinnvoll ergänzen, stellen jedoch derzeit keinen vollwertigen Ersatz für menschliche Stichproben dar.

Literaturverzeichnis

Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C., & Wingate, D. (2023). Out of one, many: Using language models to simulate human samples. *Political Analysis*, *31*(3), 337–351. https://doi.org/10.1017/pan.2023.2

Belk, R. W. (1988). Possessions and the extended self. *Journal of Consumer Research*, *15*(2), 139–168. https://doi.org/10.1086/209154

Bisbee, J., Clinton, J. D., Dorff, C., Kenkel, B., & Larson, J. M. (2024). Synthetic Replacements for Human Survey Data? The Perils of Large Language Models. *Political Analysis*, *32*(4), 401–416. https://doi.org/10.1017/pan.2024.5

Bloch, P. H., Brunel, F. F., & Arnold, T. J. (2003). Individual Differences in the Centrality of Visual Product Aesthetics: Concept and Measurement. *Journal of Consumer Research*, *29*(4), 551–565. https://doi.org/10.1086/346250

Bogner, K., & Landrock, U. (2015). *Antworttendenzen in standardisierten Umfragen (GESIS Survey Guidelines)Antworttendenzen in standardisierten Umfragen (GESIS Survey Guidelines)* (Techn. Ber.) (Version Number: 1.1). GESIS - Leibniz Institute for the Social Sciences. https://doi.org/10.15465/GESIS-SG_016

Brand, J., Israeli, A., & Ngwe, D. (2023). Using GPT for market research. *SSRN Electronic Journal*. https://doi.org/10.2139/ssrn.4395751

Brown, M. B., & Forsythe, A. B. (1974). Robust tests for the equality of variances. *Journal of the American Statistical Association*, *69*(346), 364–367. https://doi.org/10.1080/01621459.1974.10482955

Charness, G., Gneezy, U., & Kuhn, M. A. (2012). Experimental methods: Between-subject and within-subject design. *Journal of Economic Behavior & Organization*, *81*(1), 1–8. https://doi.org/10.1016/j.jebo.2011.08.009

Choi, E. C., Kim, Y., Pugalenthi, P., Chen, H.-E., & Huang, B.-R. (2026). Beyond the mean: Three-axis fidelity for aligning LLM-based survey simulators from small pilot data [Number: arXiv:2606.28963 tex.howpublished: arXiv Preprint]. https://doi.org/10.48550/arXiv.2606.28963

Cialdini, R. B., Trost, M. R., & Newsom, J. T. (1995). Preference for consistency: The development of a valid measure and the discovery of surprising behavioral implications. *Journal of Personality and Social Psychology*, *69*(2), 318–328. https://doi.org/10.1037/0022-3514.69.2.318

Eifler, S., & Leitgöb, H. (2022). Experiment. In N. Baur & J. Blasius (Hrsg.), *Handbuch Methoden der empirischen Sozialforschung* (S. 225–241). Springer Fachmedien Wiesbaden. https://doi.org/10.1007/978-3-658-37985-8_13

Greving, B. (2007). Messen und Skalieren von Sachverhalten. In S. Albers, D. Klapper, U. Konradt, A. Walter & J. Wolf (Hrsg.), *Methodik der empirischen Forschung* (S. 65–78). Gabler.

Henrich, J., Heine, S. J., & Norenzayan, A. (2010). The weirdest people in the world? *Behavioral and Brain Sciences*, *33*(2–3), 61–83. https://doi.org/10.1017/S0140525X0999152X

Hirakawa, Y., Wada, T., Morishita, K., Shimizu, R., Furusawa, T., Kham, S. H., & Saito, Y. (2024). An empirical analysis of GPT-4V's performance on fashion aesthetic evaluation. *SIGGRAPH asia 2024 technical communications*. https://doi.org/10.1145/3681758.3698022

Koffka, K. (1935). *Principles of gestalt psychology*. Harcourt, Brace.

Koo, T. K., & Li, M. Y. (2016). A Guideline of Selecting and Reporting Intraclass Correlation Coefficients for Reliability Research. *Journal of Chiropractic Medicine*, *15*(2), 155–163. https://doi.org/10.1016/j.jcm.2016.02.012

Kumar, M., & Garg, N. (2010). Aesthetic principles and cognitive emotion appraisals: How much of the beauty lies in the eye of the beholder? *Journal of Consumer Psychology*, *20*(4), 485–494. https://doi.org/10.1016/j.jcps.2010.06.015

Kuric, E., Demcak, P., & Krajcovic, M. (2026, März). Synthetic Participants Generated by Large Language Models: A Systematic Literature Review. https://doi.org/10.21203/rs.3.rs-9057643/v1

Lakens, D. (2017). Equivalence tests: a practical primer for <span class=nnocase»t-tests, correlations, and meta-analyses. *Social Psychological and Personality Science*, *8*(4), 355–362. https://doi.org/10.1177/1948550617697177

Levy, S. J. (1959). Symbols for sale. *Harvard Business Review*, *37*(4), 117–124.

Li, B., Wei, Q., & Wang, X. (2025). *Predicting behaviors with large language model (LLM)-powered digital twins of consumers* (MSI Working Paper Nr. 25-135). Marketing Science Institute.

McCracken, G. (1986). Culture and consumption: a theoretical account of the structure and movement of the cultural meaning of consumer goods. *Journal of Consumer Research*, *13*(1), 71–84. https://doi.org/10.1086/209048

Park, J. S., Zou, C. Q., Kamphorst, J., Egan, N., Shaw, A., Hill, B. M., Cai, C., Morris, M. R., Liang, P., Willer, R., & Bernstein, M. S. (2024). Generative agent simulations of 1,000 people [Number: arXiv:2411.10109 tex.howpublished: arXiv Preprint]. https://doi.org/10.48550/arXiv.2411.10109

R Core Team. (2025). R: A language and environment for statistical computing. https://www.R-project.org/

Rahimipouri, E., & Ghaitaranpour, A. (2026). Bridging the gap between human-based and AI-based food perception: a comparative study of sensory preferences across gender and age groups. *Food Quality and Preference*, *135*, 105724. https://doi.org/10.1016/j.foodqual.2025.105724

Reber, R., Schwarz, N., & Winkielman, P. (2004). Processing fluency and aesthetic pleasure: Is beauty in the perceiver's processing experience? *Personality and Social Psychology Review*, *8*(4), 364–382. https://doi.org/10.1207/s15327957pspr0804_3

Rieder, T., Schneider, M., Truss, M., Tsaplin, V., Rublea, A., Dere, S., Chicharro Sanz, F., Reiss, T., & Dogan, M. D. (2026). SimAB: Simulating A/B tests with persona-conditioned AI agents for rapid design evaluation [Number: arXiv:2603.01024 tex.howpublished: arXiv Preprint]. https://doi.org/10.48550/arXiv.2603.01024

Ruvio, A., Shoham, A., & Makovec Brenčič, M. (2008). Consumers' need for uniqueness: short-form scale development and cross-cultural validation. *International Marketing Review*, *25*(1), 33–53. https://doi.org/10.1108/02651330810851872

Sarstedt, M., Adler, S. J., Rau, L., & Schmitt, B. (2024). Using large language models to generate silicon samples in consumer and marketing research: Challenges, opportunities, and guidelines. *Psychology and Marketing*, *41*(6), 1254–1270. https://doi.org/10.1002/mar.21982

Shrestha, P., Jiang, B., Xue, H., Liu, H., & Zhou, X. (2026). Multimodal large language models as synthetic participants in video-based studies: An evaluation [Number: arXiv:2606.07541 tex.howpublished: arXiv Preprint]. https://doi.org/10.48550/arXiv.2606.07541

Shrestha, P., Krpan, D., Koaik, F., Schnider, R., Sayess, D., & Binbaz, M. S. (2024). Beyond WEIRD: Can synthetic survey participants substitute for humans in global policy research? *Behavioral Science and Policy*, *10*(2), 26–45. https://doi.org/10.1177/23794607241311793

Shrout, P. E., & Fleiss, J. L. (1979). Intraclass correlations: Uses in assessing rater reliability. *Psychological Bulletin*, *86*(2), 420–428. https://doi.org/10.1037/0033-2909.86.2.420

Solomon, M. R. (1983). The role of products as social stimuli: a symbolic interactionism perspective. *Journal of Consumer Research*, *10*(3), 319–329. https://doi.org/10.1086/208971

Tian, K. T., Bearden, W. O., & Hunter, G. L. (2001). Consumers' need for uniqueness: Scale development and validation. *Journal of Consumer Research*, *28*(1), 50–66. https://doi.org/10.1086/321947

Toubia, O., Gui, G. Z., Peng, T., Merlau, D. J., Li, A., & Chen, H. (2025). Database report: Twin-2K-500: A data set for building digital twins of over 2,000 people based on their answers to over 500 questions. *Marketing Science*. https://doi.org/10.1287/mksc.2025.0262

Veryzer, R. W., & Hutchinson, J. W. (1998). The influence of unity and prototypicality on aesthetic responses to new product designs. *Journal of Consumer Research*, *24*(4), 374–394. https://doi.org/10.1086/209516

von der Heyde, L., Haensch, A.-C., & Wenz, A. (2025). Vox populi, vox AI? Using language models to estimate German public opinion. *Social Science Computer Review*. https://doi.org/10.1177/08944393251337014

Wang, J., Zhang, Y., Borhi, M., Wei, W., Li, H., et al. (2026). Where do adolescent digital twins succeed and fail? A multi-layer validation of survey-anchored generative agents with an LLM backbone [tex.howpublished: Research Square Preprint]. https://doi.org/10.21203/rs.3.rs-8823969/v1

Yoo, K., Haenlein, M., & Hewett, K. (2025). A whole new world, a new fantastic point of view: Charting unexplored territories in consumer research with generative artificial intelligence. *Journal of the Academy of Marketing Science*, *53*(3), 723–759. https://doi.org/10.1007/s11747-025-01097-2

A Aktueller Empirischer Forschungsstand

Tabelle A.1: Aktuelle empirische Untersuchungen

Studie	*n*	Domäne / Stimulus	Modell	Persona Informationen	Mittelwerte (H1)	Varianz (H2)	Subgruppen (H3)
Allgemeine und textbasierte Stimuli							
Bisbee et al. (2024)	7 530 (×30)	Politische Einstellungen (ANES); Text	GPT-3.5	Demografie-Prompts, kovariaten-gematcht	Mittel innerhalb 1 *SD*; Rangfolge erhalten	*SD* deutlich komprimiert	Partisanen um 0,5–1 *SD* verzerrt; prompt-/zeitinstabil
Shrestha et al. (2024)	k. A.	Politik-Surveys (USA, KSA, VAE); Text	GPT-4	Demografie je Land	„reasonably similar“; non-WEIRD schwächer	k. A.	kulturkreisabhängig; Positivitätsbias
Park et al. (2024) (Preprint)	1 052	GSS, Big Five, ökon. Spiele; Text	GPT-4o	2-h-Interviews (generative Agents)	85 % Test-Retest-Niveau; nur Demografie 74 %	k. A.	Disparitäten durch Interviews reduziert
von der Heyde et al. (2025)	1 905	Wahlabsicht BTW 2017 (GLES); Text, deutsch	GPT-3.5	1:1-GLES-Personas	nicht repliziert; politischer Bias	k. A.	Stereotypen replizierbar
Toubia et al. (2025)	2 058	500+ Fragen (Persönlichkeit, Konsum); Text	verschiedene	Survey-Profile („Digital Twins“)	gegen Test-Retest-Benchmark validiert	heterogene Effekte analysierbar	Individual- und Aggregatebene getrennt
Choi et al. (2026) (Preprint)	1 466	COVID-Misinformation; Text	verschiedene	Kalibrierung an Pilotdaten	Drei-Achsen-Treue; Fine-Tuning am ausgewogensten	marginale Treue als eigene Achse	Treue variiert über Subsamples
Wang et al. (2026) (Preprint)	2 023	Jugend-Risikoverhalten (YRBS); Text + RAG	verschiedene + RAG	Twins + narrative Anreicherung	Assoziationen besser als Role-Play; Narrative gemischt	k. A.	Fehlausrichtung senkt Treue
Kuric et al. (2026) (Preprint)	182 Studien	systematisches Review	verschiedene	k. A.	Gewinne „modest“; heuristikartig	Verteilungsverzerrung als Problemklasse	Fehlausrichtung, Scheinglaubwürdigkeit, Overfitting
Visuelle und multimodale Stimuli							
Rahimipouri und Ghaitaranpour (2026)	240	Lebensmittelpräferenz; visuell/sensorisch	GPT-4o	Demografie-Personas	k. A.	k. A.	Geschlecht und Alter
Shrestha et al. (2026) (Preprint)	673 Paare	Kurzvideos (PMSV); multimodal	Gemini 3 Flash; Qwen 3 Omni	Profil je Realteilnehmer	„limited agreement“; Mean-Shift nach unten	zentrale Tendenz zur Skalenmitte	inkonsistent oder Unterschiede werden ausgeglichen
Hirakawa et al. (2024)	132 905 Bewertungen	Outfit-Ästhetik (Fotos); visuell	GPT-4V	keine Personas (Rater-Setup)	ρ = 0,12–0,52 (human 0,72–0,82)	Positions-/ Reihenfolgebias	nicht untersucht
Rieder et al. (2026) (Preprint)	47 A/B-Tests	Design-Screenshots; visuell	verschiedene + RAG	Zielgruppen-Personas	67 % Treffer; High-Confidence 83 %	bias-robust getestet	Personas verbessern Prädiktion
Li et al. (2025) (Working Paper)	304	Amazon-Käufe + Reviews; nicht visuell	Qwen 2.5 7B (feingetunt)	Fine-Tuning auf Review-Historien	Accuracy 0,86 (Basis 0,54)	steigt mit Historientiefe	k. A.

Anmerkungen. Einschlusskriterien: Relevante empirische Veröffentlichungen und systematische Reviews zum Thema Menschliche und Synthetische Stichprobenvergleiche (Abbildungstreue) in der Marktforschung, Publikationszeitraum August 2024 bis August 2026, Recherche via Websuche und Scite-Volltextsuche. Da keine einheitliche Einheit für den Grad der Abbildungstreue verwendet wird, wird die jeweils veröffentlichte Kennzahl berichtet. Es wurden Preprints einbezogen, diese sind entsprechend gekennzeichnet.

B Stimulusübersicht

Tabelle B.1: Eingesetzte Stimuli der Hauptstudie

Stimulus	Stufe	Stil	Konsistenz	Inhalt
`Min_Top`	K1	Minimalismus	—	Oberteil
`Min_Bottom`	K1	Minimalismus	—	Unterteil
`Boho_Top`	K1	Hippie/Boho	—	Oberteil
`Boho_Bottom`	K1	Hippie/Boho	—	Unterteil
`HipHop_Top`	K1	HipHop/Streetwear	—	Oberteil
`HipHop_Bottom`	K1	HipHop/Streetwear	—	Unterteil
`MIN_konsistent`	K2	Minimalismus	konsistent	Oberteil + Unterteil
`BOHO_konsistent`	K2	Hippie/Boho	konsistent	Oberteil + Unterteil
`HH_B_inkonsistent`	K2	HipHop + Boho	inkonsistent	Oberteil + Unterteil
`EN_konsistent`	K3	Minimalismus	konsistent	Outfit-Ensemble
`EN_inkonsistent`	K3	verschiedene	inkonsistent	Outfit-Ensemble

Anmerkung. K1 = Einzelprodukt, K2 = Zweiteilige Kombination, K3 = Ensemble.

C Prompts und Code

C.1 Prompts

C.1.1 Chinesisch

Code/Prompt C.1: Systemprompt (chinesisch)

```
你将扮演一位特定人物的角色，并以该人物的视角完成一份市场调查问卷。请注意：

- 请完全从该人物的角度作答。
- 请仅使用规定的答案格式和量表（所有量表均为 1 至 ）。5
- 请勿捏造任何关于该人物或产品的额外信息。
- 除非明确要求，否则请勿给出任何理由。
- 答案没有对错之分；请从该角色的角度诚实作答。
- 仅输出所要求的答案值。请勿输出任何关于本研究本身的信息
  （不包含 、、、刺激类型、标题persona_idrunstimulus_id标签）。/
- 请严格遵守末尾规定的输出格式。
```

Code/Prompt C.2: Persona Prompt (chinesisch)

```
你今年
 {age} 岁，性别为 {gender，目前的主要职业是：}{occupation。你主要成长于} {cultural_background} 文化环境。你的家庭月净收入为

 {income_net_hh。你每月在服装和时尚配饰上的支出约为} {clothing_budget_month。}时尚作为你个性组成部分的重要程度为
 {fashion_involvement_1_5} 分（满分 5 分，1 = 完全不重要，5 = 非常重要）。你偏好的品牌购物地点：

/{favorite_brands。}你的态度（每项均为

 1 = 非常低 至 5 = 非常高）：
- 对消费独特性的需求：{CNFU_mean。}
- 产品美感设计对你的重要程度：/{CVPA_mean。}
- 对一致性稳定性的偏好：/{PFC_mean。}你的风格倾向（

1–5 分，该风格与你口味的契合程度）：
- 极简主义（简洁线条、柔和色调、优雅）：{style_min_1_5}
- 波西米亚嬉皮风（飘逸剪裁、大地色系、天然材质）：/{style_boho_1_5}
- 嘻哈街头风（宽松剪裁、高对比度色彩、都市风格）：/{style_hiphop_1_5}请在整个调查过程中保持此角色一致。
```

Code/Prompt C.3: Prompt Einzelprodukt (chinesisch)

```
在本提示之后，你将收到一张产品图片。请查看所示产品，并按以下顺序回答问题。


1) “这件产品给人的感觉是……”（请对每个形容词评分；1 = 完全不符合，5 = 完全符合）运动的
 | 街头的 | 贴近自然的 | 浪漫的 | 简约的 | 保守的

2) 请评价该产品（1 至 ）：5
   - “我喜欢这件产品。”（1 = 完全不符合，5 = 完全符合）
   - “我对这件产品有好感。”（1 = 完全不符合，5 = 完全符合）
   - “我觉得这件产品很有吸引力。”（1 = 完全不符合，5 = 完全符合）

3) 请评价该产品（1 至 ）：5
   - 劣质的 (1) ... 优质的 (5)
   - 简单的 (1) ... 奢华的 (5)
   - 便宜的 (1) ... 昂贵的 (5)

4) 你预期该产品会以什么价格出售？请以欧元填写金额（仅限整数，无需货币符号）。

5) 你会把这件产品最主要地归为哪种风格？
   HipHop/Streetwear (1) / Minimalismus (2) / Hippie/Boho (3) / keine der Genannten (5)
      ↪ 请仅以宽表格格式输出答案值，不含表头、不含任何附加文本、不含引号、不含研究测试信息。


/请按以下顺序恰好输出这

 14 个答案字段：
conn_athletisch;conn_urban;conn_naturverbundenheit;conn_romantisch;conn_reduziert;conn_konservativ;
```

```
liking_gefaellt;liking_mag;liking_ansprechend;
price_minderwertig_hochwertig;price_einfach_luxurioes;price_billig_teuer;
price_expectation_rmb;
style_k1取值范围：所有李克特两极量表字段均为

/ 1–5 的整数;
price_expectation_rmb 为欧元整数; style_k1 为 {1,2,3,5} 中恰好一个具有代表性的数字。示例（仅答案值）：



4;4;3;4;3;3;3;5;3;2;1;1;39;1
```

Code/Prompt C.4: Prompt Produktkombinationen (chinesisch)

```
请查看所示的产品组合，并按以下顺序回答问题。


1) “这件产品给人的感觉是……”——请对每个形容词评分（
1 = 完全不符合，5 = 完全符合）运动的
 | 街头的 | 贴近自然的 | 浪漫的 | 简约的 | 保守的

2) 你在多大程度上认同？（1 = 完全不符合，5 = 完全符合）
   – “我喜欢这些产品。”
   – “我对这些产品有好感。”
   – “我觉得这些产品很有吸引力。”

3) 请在以下量表上评价该组合（1 至 ）：5
   – 劣质的 (1) ... 优质的 (5)
   – 简单的 (1) ... 奢华的 (5)
   – 便宜的 (1) ... 昂贵的 (5)

4) 你估计所示组合总共需要多少钱？请以欧元填写金额（仅限整数，无需货币符号）。

5) 请评价该组合（1 至 ）：5
   – 不一致 (1) ... 一致 (5)
   – 不协调 (1) ... 协调 (5)
   – 不和谐不平衡/ (1) ... 和谐平衡/ (5)

6) 你在这张图片上看到了多少件产品？请给出一个整数。

7) 你会把这些产品归入以下哪些风格？（
1 = 完全不适用，5 = 完全适用）
   – HipHop/Streetwear
   – Minimalismus
   – Hippie/Boho请仅以宽表格格式输出答案值，不含表头、不含任何附加文本、不含引号、不含研究测试信息。

/请按以下顺序恰好输出这

 20 个答案字段：
conn_athletisch;conn_urban;conn_naturverbundenheit;conn_romantisch;conn_reduziert;conn_konservativ;
liking_gefaellt;liking_mag;liking_ansprechend;
price_minderwertig_hochwertig;price_einfach_luxurioes;price_billig_teuer;
price_expectation_rmb;
cons_einheitlich;cons_stimmig;cons_harmonisch;
product_count;
style_k2_hiphop_activewear;style_k2_minimalismus;style_k2_hippie_boho取值范围：所有李克特两极风格字段均为

// 1–5 的整数;
price_expectation_rmb 为欧元整数; product_count 为整数。示例（仅答案值）：


4;4;3;4;4;4;3;5;5;2;3;1;880;5;4;5;2;2;5;1
```

C.1.2 Deutsch

Code/Prompt C.5: Systemprompt (deutsch)

```
Du übernimmst die Rolle einer konkreten Person und beantwortest eine
```

```
Marktforschungsbefragung so, wie diese Person es täte. Beachte:
- Antworte ausschließlich aus der Perspektive dieser Person.
- Nutze nur die vorgegebenen Antwortformate und Skalen (alle Skalen 1 bis 5).
- Erfinde keine Zusatzinformationen über die Person oder die Produkte.
- Gib keine Begründungen, außer es wird ausdrücklich danach gefragt.
- Es gibt keine richtigen oder falschen Antworten; antworte ehrlich aus der Rolle.
- Gib NUR die erfragten Antwortwerte aus. KEINE Angaben zur Untersuchung selbst
  (kein persona_id, run, stimulus_id, Stimulus-Typ, keine Überschriften/Labels).
- Halte dich exakt an das geforderte Ausgabeformat am Ende.
```

Code/Prompt C.6: Persona Prompt (deutsch)

```
Du bist {age} Jahre alt, {gender} und deine aktuelle Haupttätigkeit ist: {occupation}. Du bist ueberwiegend im Kulturkreis {cultural_background} aufgewachsen.

Dein monatliches Netto-Haushaltseinkommen liegt bei {income_net_hh}. Pro Monat gibst du für Kleidung und Mode-Accessoires etwa {clothing_budget_month} aus.
Wie wichtig dir Mode als Teil deiner Persönlichkeit ist, liegt bei {fashion_involvement_1_5} von 5 (1 = überhaupt nicht wichtig, 5 = sehr wichtig).

Bevorzugte Marken/Einkaufsorte: {favorite_brands}.

Deine Einstellungen (jeweils Skala 1 = sehr gering bis 5 = sehr hoch):
- Beduerfnis nach Einzigartigkeit im Konsum: {CNFU_mean}.
- Bedeutung von Produktaesthetik/Design fuer dich: {CVPA_mean}.
- Praeferenz fuer Konsistenz/Bestaendigkeit: {PFC_mean}.

Deine Stil-Affinitaet (Skala 1-5, wie sehr der Stil deinem Geschmack entspricht):
- Minimalismus (klare Linien, gedeckte Toene, Eleganz): {style_min_1_5}
- Boho/Hippie (fliessende Schnitte, Erdtoene, Naturmaterialien): {style_boho_1_5}
- HipHop/Streetwear (oversized Schnitte, kontrastreiche Farben, urbaner Look): {style_hiphop_1_5}

Bleibe über die gesamte Befragung konsistent in dieser Rolle.
```

Code/Prompt C.7: Prompt Einzelprodukt (deutsch)

```
Nach diesem Promt erhältst du ein Bild eines Produktes. Betrachte das gezeigte Produkt und beantworte die folgenden Fragen in dieser Reihenfolge.

1) Dieses Produkt wirkt... (bewerte jedes Adjektiv; 1 = trifft überhaupt nicht zu, 5 = trifft voll und ganz zu)
athletisch | urban | naturverbunden | romantisch | reduziert | konservativ

2) Bitte bewerten Sie das Produkt. (1 bis 5):
   - "Das Produkt gefällt mir gut."(1 = trifft überhaupt nicht zu, 5 = trifft voll und ganz zu)
   - "Ich mag das Produkt."(1 = trifft überhaupt nicht zu, 5 = trifft voll und ganz zu)
   - "Ich finde das Produkt ansprechend."(1 = trifft überhaupt nicht zu, 5 = trifft voll und ganz zu)

3) Bitte bewerten Sie das Produkt. (1 bis 5)
   - minderwertig (1) ... hochwertig (5)
   - einfach (1) ... luxuriös (5)
   - billig (1) ... teuer (5)

4) Für welchen Preis würden Sie erwarten, dass das Produkt angeboten wird? Gib einen
   Betrag in Euro an (nur ganze Zahl, ohne Währungssymbol).

5) Welchem Stil ordnest du dieses Produkt am ehesten zu?
   HipHop/Streetwear (1) / Minimalismus (2) / Hippie/Boho (3) / keine der Genannten (5)


Antworte AUSSCHLIESSLICH mit den Antwortwerten im Wide Table Format, KEINE Kopfzeile, KEIN zusätzlicher Text, KEINE Anführungszeichen , KEINE Studien-/Test-Angaben

Gib genau diese 14 Antwortfelder in dieser Reihenfolge aus:
conn_athletisch;conn_urban;conn_naturverbundenheit;conn_romantisch;conn_reduziert;conn_konservativ;
liking_gefaellt;liking_mag;liking_ansprechend;
price_minderwertig_hochwertig;price_einfach_luxurioes;price_billig_teuer;
price_expectation_rmb;
style_k1

```

```
Wertebereiche: alle Likert-/Differential-Felder = ganze Zahl 1-5;
price_expectation_eur = ganze Zahl in Euro; style_k1 = genau EINE repräsentative Zahl aus {1,2,3,5}.

Beispiel (nur Antwortwerte):

4;4;3;4;3;3;3;5;3;2;1;1;39;1
```

Code/Prompt C.8: Prompt Produktkombinationen (deutsch)

```
Betrachte die gezeigten Produkt-Kombination und beantworte die folgenden Fragen
in dieser Reihenfolge.

1) Dieses Produkt wirkt... — bewerte jedes Adjektiv
 (1 = trifft überhaupt nicht zu, 5 = trifft voll und ganz zu)
athletisch | urban | naturverbunden | romantisch | reduziert | konservativ

2) Wie sehr stimmst du zu? (1 = trifft überhaupt nicht zu, 5 = trifft voll und ganz zu)
   - "Die Produkte gefallen mir gut."
   - "Ich mag die Produkte."
   - "Ich finde die Produkte ansprechend."

3) Bewerte die Kombination auf folgenden Skalen (1 bis 5):
   - minderwertig (1) ... hochwertig (5)
   - einfach (1) ... luxuriös (5)
   - billig (1) ... teuer (5)

4) Was schätzt du, wie viel kostet die gezeigte Kombination insgesamt? Gib einen
   Betrag in Euro an (nur ganze Zahl, ohne Währungsymbol).

5) Bewerte die Kombination (1 bis 5):
   - uneinheitlich (1) ... einheitlich (5)
   - unstimmig (1) ... stimmig (5)
   - unharmonisch/unausgewogen (1) ... harmonisch/ausgewogen (5)

6) Wie viele Produkte siehst du auf diesem Bild? Geben Sie eine ganze Zahl an.

7) In welche der folgenden Stile würden Sie die Produkte einordnen?
(1 = passt überhaupt nicht an, 5 = passt voll und ganz an)
   - HipHop/Streetwear
   - Minimalismus
   - Hippie/Boho

Antworte AUSSCHLIESSLICH mit den Antwortwerten im Wide Table Format, KEINE Kopfzeile, KEIN zusätzlicher Text, KEINE Anführungszeichen
      ↪ , KEINE Studien-/Test-Angaben

Gib genau diese 20 Antwortfelder in dieser Reihenfolge aus:
conn_athletisch;conn_urban;conn_naturverbundenheit;conn_romantisch;conn_reduziert;conn_konservativ;
liking_gefaellt;liking_mag;liking_ansprechend;
price_minderwertig_hochwertig;price_einfach_luxurioes;price_billig_teuer;
price_expectation_rmb;
cons_einheitlich;cons_stimmig;cons_harmonisch;
product_count;
style_k2_hiphop_activewear;style_k2_minimalismus;style_k2_hippie_boho

Wertebereiche: alle Likert-/Differential-/Stil-Felder = ganze Zahl 1-5;
price_expectation_eur = ganze Zahl in Euro; product_count ist eine ganze Zahl.

Beispiel (nur Antwortwerte):
4;4;3;4;4;4;3;5;5;2;3;1;880;5;4;5;2;2;5;1
```

C.2 Code

Code/Prompt C.9: R-Code zur Verarbeitung von Mittelwerten und Varianzen (conn_*)

```r
# 1. conn_*
conn_vars <- c(
  "conn_athletisch",
  "conn_urban",
  "conn_natur",
  "conn_roma",
  "conn_reduziert",
  "conn_konservativ"
)
conn_vars

k1_mean_person <- k1_clean %>%
  group_by(respondent_id, source) %>%
  summarise(
    across(
      all_of(conn_vars),
      ~ mean(.x, na.rm = TRUE)
    ),
    .groups = "drop"
  )
k1_mean_person

k1_mean_paired <- k1_mean_person %>%
  pivot_wider(
    names_from = source,
    values_from = all_of(conn_vars),
    names_sep = "_"
  )
k1_mean_paired

paired_t_conn <- function(data, var) {
  human_col <- paste0(var, "_human")
  ai_col    <- paste0(var, "_synthetic")
  temp <- data %>%
    select(
      human = all_of(human_col),
      ai    = all_of(ai_col)
    ) %>%
    drop_na()

  diff <- temp$ai - temp$human
  test <- t.test(
    temp$ai,
    temp$human,
    paired = TRUE
  )

  tibble(
    variable = var,
    n_pairs = nrow(temp),

    mean_human = mean(temp$human),
    mean_AI = mean(temp$ai),

    mean_difference_AI_minus_Human = mean(diff),
    sd_difference = sd(diff),

    t = unname(test$statistic),
    df = unname(test$parameter),
    p_value = test$p.value,

    CI_low = test$conf.int[1],
    CI_high = test$conf.int[2]
  )
}

k1_ttest_results <- map_dfr(
  conn_vars,
  ~ paired_t_conn(k1_mean_paired, .x)
```

```
)
k1_ttest_results
```

Code/Prompt C.10: R-Code zur Analyse der Subgruppenmuster (H3)

```
main_results <- run_all_conditions(
  dat = master,
  cluster_vars = cluster_vars_main,
  k = K_CLUSTERS,
  seed = 2025L,
  nstart = KMEANS_NSTART,
  n_perm = N_PERMUTATIONS
)

metrics <- main_results$metrics |>
  dplyr::mutate(
    complexity = factor(
      complexity,
      levels = c("Single", "Combination", "Ensemble"),
      ordered = TRUE
    ),
    consistency = dplyr::case_when(
      stringr::str_detect(condition, "INKONSISTENT") ~ "inkonsistent",
      complexity == "Single" ~ "nicht_anwendbar",
      TRUE ~ "konsistent"
    )
  ) |>
  dplyr::arrange(complexity, condition)

cat("\nHauptkennwerte je Bedingung:\n")
print(metrics, n = Inf)

metric_names <- c(
  "sCMAE",
  "cluster_size_TVD",
  "matching_accuracy",
  "cohen_kappa",
  "ARI",
  "price_log_sCMAE"
)

summary_complexity <- metrics |>
  dplyr::group_by(complexity) |>
  dplyr::summarise(
    n_conditions = dplyr::n(),
    dplyr::across(
      dplyr::all_of(metric_names),
      list(
        mean = ~ mean(.x, na.rm = TRUE),
        sd = ~ stats::sd(.x, na.rm = TRUE),
        min = ~ min(.x, na.rm = TRUE),
        max = ~ max(.x, na.rm = TRUE)
      ),
      .names = "{.col}_{.fn}"
    ),
    .groups = "drop"
  )

cat("\nZusammenfassung nach Komplexitaet:\n")
print(summary_complexity, n = Inf)
```